

5G 코어망 환경에서의 머신러닝 기반 트래픽 처리량 예측

최준서*,김민규*,김종현**

세종대학교 (학부생*,교수**)

Machine Learning-based Traffic Throughput Prediction in a 5G Core Network Environment

Jun-Seo Choi*,Min-gyu Kim*,Jong-hyun Kim**

Sejong University(Undergraduate researcher*,Professor**)

요약

본 연구는 자체 5G 테스트베드를 구축하여, 기지국과 코어망 간의 인터페이스를 통한 트래픽 처리량 및 기지국과 코어망의 리소스 사용량을 측정하였다. 또한, 수집된 리소스 데이터를 활용하여 머신러닝 기반의 네트워크 처리량 예측을 수행하였다. Random Forest Regressor 모델 학습 결과, 네트워크 처리량을 결정 계수(R^2) 0.9587 및 RMSE 약 9.64Mbps로 예측하여 높은 성능을 기록하였다. 이는 5G 코어망 환경에서 시스템 리소스 데이터를 기반으로 네트워크 처리량을 효과적으로 예측할 수 있음을 실증적으로 입증한다.

I. 서론

최근 5G 이동통신 기술은 초고속, 초저지연을 바탕으로 다양한 분야의 핵심 인프라로 자리 잡았으며, 여러 종류 및 대량의 기기 접속으로 인한 네트워크 트래픽의 복잡성은 기하급수적으로 증가하고 있다. 하지만, 기존의 정적 관리 방식으로 급변하는 트래픽 환경에 효율적으로 신속하게 대응하기 어려워 네트워크 혼잡 및 서비스 품질 저하를 야기할 수 있다. 이러한 문제를 해결하기 위해, 본 연구는 5G 테스트베드를 구축하고 머신러닝 모델을 활용하여 네트워크 처리량을 성공적으로 예측하고자 했다. 이를 통해 네트워크 관리자가 CPU 사용량과 같은 핵심 리소스의 변화를 바탕으로 네트워크 처리량을 사전에 인지하고, 예측된 처리량 정보를 바탕으로 안정적인 서비스 품질(QoS)을 보장하기 위한 5G 코어망 서버 자원 최적화 방안의 기반을 마련하고자 했다.

II. 관련연구

지세현 등의 연구에서는 학내망에서 수집된 TCP/UDP 트래픽 데이터를 사용하여 RNN 모델의 예측 성능을 검증하였으나, 해당 연구는 트래픽의 발생 ‘양’을 예측하는 데 중점을 두어 네트워크 ‘처리량’에 직접적인 영향을 미치는 다른 성능 지표와의 관계는 분석하지 않았다.[1] 국외에서는 5G 엣지 환경의 처리량 예측을 위해 연합 학습(Federated Learning)과 LSTM, Transformer 같은 최신 시계열 모델을 활용하는 연구가 진행되었다.[2] 이 연구는 실제 5G망에서 수집된 다양한 데이터셋을 활용하여 높은 예측 성능을 입증했으나, 공개된 데이터셋을 이용한 시뮬레이션에 기반하고 있어 실제 물리적 테스트베드에서의 검증이 필요하다는 한계점을 가진다.

III. 연구 방법

3.1 데이터 수집

본 연구는 모델 학습 및 예측에 사용하는 시계열 데이터를 두 개의 VM으로 구성된 5G 테스트베드 환경(VM1:UE/gNB, VM2:5G Core)에서 수집하였다. iperf3 도구를 활용하여, 네트워크 트래픽 부하를 서버에 지속해서 주었으며, 그와 동시에 Prometheus와 Psutil을 사용하여 두 VM으로부터 각종 리소스 사용 데이터를 수집하였다. 수집한 데이터의 피쳐는 표 1과 같다.

[표 1] 모델 학습 및 평가 데이터의 피쳐

Feature	설명
vm1_cpu_usage	클라이언트(VM1)의 CPU 사용량 (%)
vm1_memory_usage	클라이언트(VM1)의 메모리 사용량 (%)
vm1_load1	클라이언트(VM1)의 1분 평균 시스템 부하
core_cpu_usage	5G Core의 CPU 사용량 (%)
vm2_memory_usage	서버(VM2)의 메모리 사용량 (%)
vm2_load1	서버(VM2)의 1분 평균 시스템 부하
network_throughput_bps	네트워크 처리량 (bps)

3.2 모델 아키텍처 및 하이퍼파라미터

네트워크 처리량 예측을 위해, Random Forest Regressor 모델을 사용하였다. 모델의 하이퍼파라미터는 표 2와 같이 설정하였다.

[표 2] 모델의 하이퍼파라미터 설정 값

Hyperparameter	설정 값
n_estimators	100
criterion	'squared_error'
min_samples_split	2
random_state	42
min_samples_leaf	1
min_impurity_decrease	0.1


3.3 네트워크 처리량 예측

네트워크 처리량 예측을 위해 채택한 Random

Forest Regressor 모델의 작동 원리는 다음과 같다. 먼저, 원본 학습 데이터에서 무작위로 샘플을 추출하여 여러 개의 서브 데이터셋을 만든 후 각 서브 데이터셋으로 개별 결정 트리를 학습시키는데, 이때 각 트리의 노드를 분할할 때 모든 변수를 고려하는 대신 일부 변수만을 무작위로 선택한다. 이 과정을 통해 각 트리는 데이터의 서로 다른 측면을 학습하게 되어 과적합을 방지하고 일반화 성능을 높인다. 최종 예측 시에는, 생성된 모든 결정 트리가 각각 예측한 처리량 값들의 평균을 계산하여 최종 예측값으로 사용한다. 학습된 모델의 예측 성능을 객관적으로 평가하기 위해 결정 계수와 제공된 평균 제곱 오차를 사용했다.

IV. 실험 및 결과

4.1 실험 환경



[그림 1] 리소스 사용량 수집 구조

Ubuntu 가상 머신 두 대를 이용하여 5G 테스트베드 환경을 구축했다. VM1은 트래픽을 생성하는 사용자 단말(UE/클라이언트)로, VM2는 트래픽을 수신하는 5G Core 네트워크(서버)로 역할을 설정했다. VM1에서 실행되는 Python Scraper가 Psutil과 Prometheus를 이용하여 가져온 각 가상 머신의 시스템 자원(CPU, 메모리, 부하 등)과 네트워크 처리량을 1초마다 동기적으로 수집하여, 모든 데이터를 타임스탬프와 함께 CSV파일로 통합 저장했다.

4.2 데이터 수집 및 전처리

수집된 데이터는 모델의 학습 성능과 안정성을 높이기 위해 두 단계의 전처리 과정을 수행했다.

첫 번째 단계는 이상치 제거이다. 5G Core의 CPU 사용량을 기준으로, 데이터의 사분위수 범위(IQR)를 벗어나는 값을 이상치로 간주하고 제거했다. 이는 비정상적인 네트워크 상태로 인해 발생한 극단적인 값이 모델 학습을 방해하는 것을 방지한다.

두 번째 단계는 특성 스케일링이다. 각 입력 변수는 서로 다른 단위와 값의 범위를 가지므로, StandardScaler를 사용하여 모든 특성의 평균을 0, 표준편차를 1로 변환하는 표준화를 진행했다. 이를 통해 모든 변수가 모델 학습에 동등한 영향력을 갖도록 조정하였다.

3시간 동안 수집하였으며, 수집한 데이터의 크기는 882KB이다. 총 6420개의 데이터행이 수집되었다.

4.3 모델 학습 및 성능 결과 분석

이상치가 제거된 데이터셋으로 학습된 모델의 성능을 평가한 결과, 결정 계수(R^2)는 0.9587을 기록하여 모델이 네트워크 처리량 변화의 약 95.9%를 성공적으로 설명함을 확인했다. 제공된 평균 오차(RMSE)는 약 9.64 Mbps로 나타나 Gbps 단위의 실제 처리량 예측에 있어 매우 낮은 오차율을 보였다. 6420개의 데이터에서 5G Core의 CPU 사용량을 기준으로 IQR방식을 사용하여 정상 범위를 벗어나는 49개의 데이터를 이상치로 판단하고 제거한 후 6371개의 새로운 데이터셋으로 모델학습을 진행했다.

[표 3] 실제 처리량과 모델 예측 처리량 비교

실제 처리량(Gbps)	모델 예측 처리량(Gbps)	오차
0.07	0.06	0.01
0.05	0.05	0.00
0.03	0.02	0.01
0.15	0.15	0.00
0.13	0.13	0.00
0.09	0.09	0.00

V. 결론

본 연구는 자체 5G 테스트베드에서 수집한 리소스 데이터(IQR 이상치 제거, 6,371개)를 활용하여 머신러닝 기반 처리량 예측을 수행했다. Random Forest Regressor 모델 학습 결과, 결정계수(R^2) 0.9587 및 RMSE 약 9.64 Mbps의 높은 성능을 기록하였다. 이는 5G 코어망 환경에서 시스템 리소스 사용량을 바탕으로 네트워크 트래픽 처리량을 성공적으로 예측할 수 있음을 실증적으로 입증한다. 본 연구는 네트워크 관리자가 시스템 자원 상태를 기반으로 트래픽 변화를 사전에 예측하고, 안정적인 서비스 품질(QoS)을 보장하기 위한 서버 자원 최적화 방안의 기반을 마련했다는 점에서 의의가 있다. 다만 본 연구는 2개의 가상머신으로 구성된 제한된 환경이기에, 향후 분산 코어/엣지, 네트워크 슬라이스 등이 적용된 실제 5G 환경에서의 검증이 필요하다. 또한, 현재 리소스 기반 예측을 위해 사용한 Random Forest Regressor 모델 외에도 시계열 특성을 반영한 LSTM, GRU 모델의 적용과, 보안 위협 등 비정상 트래픽 탐지 등의 연구 확장이 필요할 것이다.

Acknowledgement

이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구 결과임(No. RS-2025-25404706, 6G NTN 글로벌 생태계 신뢰체계 구축 및 국제협력)

[참고문헌]

- [1] Se-Hyun Ji, Huru Hasanova, Kyu-Seok Shim, Myung-Sup Kim "Prediction of Traffic Usage Machine Learning Algorithm For Efficient Network Management"(2018)
- [2] Dutta, Yuvraj, et al. "Benchmarking Federated Learning for Throughput Prediction in 5G Live Streaming Applications." *arXiv preprint arXiv:2508.08479v1* (2025)