

IoT 클래스 불균형 환경에서 Dual-Head 앙상블 기반 GraphSAGE 침입 탐지 모델 개선

차한솔¹ · 김종현^{2,*}

세종대학교

Improving GraphSAGE-based Intrusion Detection with Dual-Head Ensemble for Class-Imbalanced IoT Environments

Han-sol Cha¹ · Jong-hyun Kim^{2,*}

Sejong University

E-mail : sada26382@gmail.com / jhk@sejong.ac.kr

요 약

기존 GNN 기반 네트워크 침입 탐지 모델은 NF-UNSW-NB15-v3 데이터셋에서 높은 성능(Macro F1 0.974)을 달성하지만, IoT 환경 데이터셋에 적용할 경우 Macro F1이 NF-BoT-IoT-v3-merged, NF-ToN-IoT-v3에서 각각 0.435, 0.502로 크게 하락한다. 이는 Transformer MAE 재건 헤드 단독으로는 클래스 불균형 환경에서 정상 클래스를 안정적으로 식별하지 못하고, GNN 이웃 집약 과정에서 원본 엣지 피처가 희석되기 때문이다. 본 연구에서는 이를 해결하기 위해 Dual-Head 앙상블 구조를 제안한다. 첫째, SAGEConv 그래프 인코더 출력에 원본 엣지 피처를 직접 결합하는 Skip Connection을 도입하여 피처 손실을 보완한다. 둘째, Focal BCE와 Soft Macro F1 Loss를 결합한 분류기 헤드를 추가하여, 소수 클래스의 오분류 샘플에 더 큰 기울기를 부여하고 Macro F1 지표를 직접 최적화한다. 최종 이상 점수는 분류기 헤드의 출력 확률과 MAE 재건 오차를 가중 앙상블(α ·분류확률 + $(1-\alpha)$ ·정규화 재건오차)하여 산출한다. 실험 결과, NF-BoT-IoT-v3-merged와 NF-ToN-IoT-v3에서 Macro F1이 각각 0.922, 0.909로 향상되었음을 확인하였다.

ABSTRACT

The existing GNN-based network intrusion detection model achieves high performance (Macro F1 0.974) on the NF-UNSW-NB15-v3 dataset, but Macro F1 drops significantly to 0.435 and 0.502 on the IoT datasets NF-BoT-IoT-v3-merged and NF-ToN-IoT-v3, respectively. This is because the Transformer MAE reconstruction head alone fails to reliably identify the benign class under class-imbalanced conditions, and the GNN neighbor aggregation process dilutes original edge features. To address these issues, this study proposes a Dual-Head ensemble architecture. First, a Skip Connection is introduced to directly concatenate original edge features with the SAGEConv graph encoder output, compensating for feature loss. Second, a classifier head combining Focal BCE and Soft Macro F1 Loss is added, which assigns larger gradients to misclassified minority class samples and directly optimizes the Macro F1 metric. The final anomaly score is computed through a weighted ensemble of the classifier head output probability and the MAE reconstruction error (α ·classification probability + $(1-\alpha)$ ·normalized reconstruction error). Experimental results confirm that Macro F1 improved to 0.922 and 0.909 on NF-BoT-IoT-v3-merged and NF-ToN-IoT-v3, respectively.

키워드

Network Intrusion Detection, GraphSAGE, Masked Autoencoder, Dual-Head Ensemble, IoT Security

1. 서 론

IoT(Internet of Things) 환경의 급속한 확산으로 인해 연결되는 디바이스의 수가 기하급수적으로 증가함에 따라, 네트워크 보안 위협이 점차 다양화·고도화되고 있다. IoT 디바이스는 제한된 연산 자원과 저전력 구조로 인해 강력한 보안 기능을 내장하기 어려우며, 그 결과 봇넷 감염, DDoS

공격 등 다양한 형태의 사이버 공격에 대한 주요 표적이 되고 있다. 이에 따라 네트워크 트래픽을 실시간으로 분석하여 이상 행위를 탐지하는 네트워크 침입 탐지 시스템(NIDS)의 필요성이 증대하고 있다. 최근에는 네트워크 트래픽을 노드와 엣지로 구성된 그래프로 모델링하고, 그래프 신경망(GNN)을 통해 호스트 간 상호작용 패턴을 학습하는 연구가 활발히 진행되고 있는데[3], 특히 GraphSAGE[2]와 Transformer 기반 Masked

* 교신저자

Autoencoder(MAE)[4]를 결합한 모델[1]은 NF-UNSW-NB15-v3 데이터셋에서 높은 성능을 달성하여, 자기도 학습 기반 침입 탐지의 가능성을 제시하였다. 그러나 동일한 모델을 IoT 환경 데이터셋에 적용할 경우 모델의 성능이 크게 저하되는 문제가 확인된다. 이는 모델이 실제 IoT 환경의 극심한 클래스 불균형을 충분히 고려하지 못하고 있음을 의미한다.

본 연구는 이러한 성능 저하의 원인을 두 가지로 분석한다. 첫째, 공격 클래스가 전체 데이터의 대부분을 차지하고 정상 클래스가 소수인 IoT 불균형 환경에서, 재건 오차 기반의 MAE 헤드만으로는 소수 정상 클래스를 안정적으로 식별하지 못한다. 둘째, GraphSAGE의 이웃 집약 과정에서 다수의 이웃 노드 정보가 평균화됨에 따라 각 플로우가 가지는 원본 엣지 피처의 세밀한 통계적 특성이 희석된다.

이를 해결하기 위해 본 연구는 SAGEConv 출력에 원본 엣지 피처를 직접 결합하는 Skip Connection과 Focal BCE 및 Soft Macro F1 Loss를 결합한 분류기 헤드를 도입한 Dual-Head 앙상블 구조를 제안한다.

II. 관련 연구

2.1 GraphSAGE 기반 네트워크 침입 탐지

Hamilton et al.이 제안한 GraphSAGE[2]는 이웃 노드의 특성을 샘플링하여 집약하는 귀납적 그래프 신경망이다. 네트워크 트래픽을 그래프로 모델링하여 노드와 엣지 간 관계를 학습하는 방식은 전통적인 머신러닝 기반 탐지 방법 대비 높은 탐지 성능을 보이며[3], SAGEConv 레이어를 통해 이웃 노드 피처를 집약하여 노드 임베딩을 생성한다.

2.2 Masked Autoencoder 기반 이상 탐지

MAE(Masked Autoencoder)[4]는 입력 데이터의 일부를 마스킹하고 재건하는 방식으로 정상 패턴을 학습한다. 재건 오차가 높은 샘플을 이상으로 판단하는 방식은 비지도 학습 기반 이상 탐지에 효과적이거나, 클래스 불균형이 심한 IoT 환경에서는 재건 오차만으로 정상과 이상을 구분하기 어렵다는 한계가 있다.

2.3 클래스 불균형 처리 기법

Focal Loss[5]는 오분류 샘플에 더 큰 가중치를 부여하여 소수 클래스 학습을 강화한다. Soft Macro F1 Loss[6]는 Macro F1 지표를 미분 가능한 형태로 근사하여 손실 함수로 직접 사용함으로써 클래스 불균형 환경에서 균형 잡힌 성능을 달성한다.

III. 제안 모델

3.1 전체 아키텍처

제안 모델은 Skip Connection이 결합된 SAGEConv 그래프 인코더, Transformer 기반 MAE 재건 헤드, Focal BCE와 Soft Macro F1 Loss를 활용한 분류기 헤드의 세 가지 구성 요소로 이루어진다. 입력 네트워크 트래픽 그래프는 인코더를 통해 노드 임베딩으로 변환되며, 두 헤드가 독립적으로 이상 점수를 산출한 후 앙상블을 통해 최종 탐지 결과를 생성한다.

3.2 Skip Connection을 통한 엣지 피처 보존

기존 GraphSAGE의 이웃 집약 과정은 원본 엣지 피처의 세밀한 패턴을 희석시킨다. 이를 해결하기 위해 SAGEConv 인코더 출력 h_v 에 원본 엣지 피처 e_v 를 직접 결합하는 Skip Connection을 도입한다. 이를 통해 지역적 트래픽 특성 정보를 직접 보완하며, 단기 공격 패턴이나 비정상 트래픽의 미세한 특성을 효과적으로 유지한다.

3.3 Dual-Head 구조 및 손실 함수

MAE 재건 헤드는 기존 Transformer MAE 구조를 유지하여 정상 트래픽 패턴을 학습하고 재건 오차 L_{rec} 를 산출한다. 분류기 헤드는 복합 손실 함수를 적용한다. Focal BCE Loss[5]는 소수 클래스 오분류 샘플에 더 큰 기울기를 부여하고, Soft Macro F1 Loss[6]는 Macro F1 지표를 직접 최적화하여 클래스 불균형 환경에서의 탐지 성능을 향상시킨다.

3.4 가중 앙상블 이상 점수

최종 이상 점수 S 는 분류기 헤드의 출력 확률 p_{cls} 와 정규화된 MAE 재건 오차 r_{norm} 를 가중 앙상블하여 산출한다. 가중치 α 는 검증 데이터를 통해 최적화되며, 두 헤드의 상호 보완적 특성을 활용하여 다양한 공격 유형에 대한 강건한 탐지를 가능하게 한다.

IV. 실험 결과

4.1 실험 환경 및 데이터셋

실험에는 NetFlow 기반 IoT 침입 탐지 벤치마크인 NF-BoT-IoT-v3-merged와 NF-ToN-IoT-v3를 사용하였다. NF-BoT-IoT-v3-merged는 NF-BoT-IoT-v2와 NF-BoT-IoT-v3의 공통 피처만을 추출하여 병합한 데이터셋으로, 서로 다른 버전 간 피처 호환성을 확보하면서도 더 많은 학습 데이터를 활용할 수 있도록 구성되었다. 두 데이터셋 모두 정상 클래스 대비 공격 클래스 비율이 극히 낮은 클래스 불균형 특성을 지니므로, 학습의 편향을 방지하기 위해 학습 시에는 편향 방지를 위해 정상·악성 동수 샘플링을 적용하였으며, 테스트 시에는 각 데이터셋의 원본 클래스 분포를 그대로 유지하여 성능을 평가하였다.

실험은 재현성을 위해 $seed=42$ 를 기준으로 5회

반복 수행하였으며, 모든 성능 지표는 5회 실험의 평균값으로 보고한다. 평가 지표로는 클래스 불균형에 민감한 Macro F1을 주요 지표로 사용하였고, Weighted F1, PR-AUC, ROC-AUC를 보조 지표로 사용한다.

4.2 비교 실험

표 1은 베이스라인 모델과 제안 모델의 성능을 Macro F1, PR-AUC, ROC-AUC 기준으로 비교한 결과이다. 제안 모델은 NF-BoT-IoT-v3-merged에서 Macro F1 0.922를 달성하여 베이스라인(0.435) 대비 48.7% 향상되었으며, NF-ToN-IoT-v3에서는 0.909를 달성하여 베이스라인(0.502) 대비 40.7% 향상되었다. 제안 모델은 분류기 헤드가 명시적인 경계 학습을 수행함으로써 실제 운영 환경에서 사용 가능한 임계값 기반 판별 성능을 크게 개선하였다.

모델	데이터셋	Macro F1	PR-AUC	ROC-AUC
베이스라인	NF-BoT-IoT-v3	0.599	0.996	-
	NF-BoT-IoT-v3-merged	0.435	0.990	-
	NF-ToN-IoT-v3	0.502	0.428	-
제안 모델	NF-BoT-IoT-v3-merged	0.922	0.985	0.965
	NF-ToN-IoT-v3	0.909	0.954	0.961

표 1. 베이스라인, 제안 모델의 성능 비교

4.3 성능 분석

표 2는 제안 모델의 클래스별 상세 성능을 나타낸다. NF-BoT-IoT-v3-merged에서 Benign F1 0.882, Malicious F1 0.962를 달성하였으며, NF-ToN-IoT-v3에서는 Benign F1 0.923, Malicious F1 0.895를 기록하였다. 두 데이터셋 모두에서 Macro F1 기준으로 큰 폭의 성능 향상이 확인되어 클래스 불균형 문제가 효과적으로 개선되었음을 확인할 수 있다.

데이터셋	Benign F1	Malicious F1	Macro F1	Weighted F1
NF-BoT-IoT-v3-merged	0.882	0.962	0.922	0.943
NF-ToN-IoT-v3	0.923	0.895	0.909	0.911

표 2. 제안 모델의 클래스별 상세 성능

V. 결론

본 연구에서는 IoT 클래스 불균형 환경에서 GraphSAGE 기반 네트워크 침입 탐지 성능을 개

선하기 위한 Dual-Head 앙상블 구조를 제안하였다. SAGEConv 인코더 출력에 원본 엣지 피처를 직접 결합하는 Skip Connection을 적용하여, 이웃 집약 과정에서 희석되는 플로우 단위의 세밀한 통계적 특성을 보존하였다. 또한 Focal BCE Loss와 Soft Macro F1 Loss를 결합한 분류기 헤드를 추가하여, 소수 클래스 오분류 샘플에 집중적인 학습 신호를 제공하고 Macro F1 지표를 손실 함수 수준에서 직접 최적화하였다. 최종 판별은 MAE 재건 헤드와 분류기 헤드의 출력을 가중 앙상블하여 수행함으로써, 재건 오차 기반의 이상 탐지 능력과 명시적 경계 학습 기반의 분류 능력을 상호 보완하였다.

실험 결과, NF-BoT-IoT-v3-merged에서 Macro F1이 0.435에서 0.922로, NF-ToN-IoT-v3에서 0.502에서 0.909로 향상되었다. 이는 제안 구조의 각 구성 요소가 클래스 불균형 문제를 보완하고 있음을 보여준다.

향후 연구에서는 실제 IoT 엣지 디바이스에 적용 가능하도록 모델 경량화 및 추론 속도 최적화를 수행한다. 또한 학습 과정에서 보지 못한 제로데이 공격 유형에 대한 일반화 성능을 검증하고, 온라인 학습 방식을 통한 신규 공격 패턴 적응 메커니즘을 탐구한다.

Acknowledgement

이 논문은 2026년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임 (No.RS-2024-00444170, 6G 개방형 네트워크 환경에서 트러스트 모델 기반 지능형 침해 대응 기술 연구 및 국제협력)

References

- [1] E. G. Mindula and P. Poornachandran, "GNN-based Network Intrusion Detection System Using Transformer MAE," in Proc. IEEE ICCE, pp. 1-6, 2023.
- [2] W. L. Hamilton, R. Ying, and J. Leskovec, "Inductive Representation Learning on Large Graphs," in Proc. NIPS, pp. 1024-1034, 2017.
- [3] M. Bilot et al., "Graph Neural Networks for Intrusion Detection: A Survey," IEEE Access, Vol. 11, pp. 49114-49139, 2023.
- [4] K. He, X. Chen, S. Xie, Y. Li, P. Dollar, and R. Girshick, "Masked Autoencoders Are Scalable Vision Learners," in Proc. CVPR, pp. 16000-16009, 2022.
- [5] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, "Focal Loss for Dense Object Detection," in Proc. ICCV, pp. 2980-2988, 2017.
- [6] M. Maceas-Rodriguez, J. Luque, "Maximizing the F-Measure via Soft F1 Loss," arXiv:2108.10566, 2021.