

5G/6G V2X 환경에서의 Prediction-AutoEncoder 기반 CAM 변조 공격 탐지 모델

김준식*, 서예린*, 김민규**, 김종현**

*, **, *** 세종대학교 정보보호학과 (학부생*, 대학원생** 교수***)

e-mail : kjs4072@sju.ac.kr

Prediction-AutoEncoder-Based Detection Model for CAM Falsification Attacks in 5G/6G V2X Environments

Junsik Kim, Yearin Seo, Mingyu Kim, Jonghyun Kim

1. 서론

차량 간 통신(Vehicle-to-Everything, V2X)은 자율주행과 지능형 교통 시스템(ITS)의 핵심 요소로, 도로 안전성과 교통 효율성을 향상시키는 데 기여하고 있다. 특히 V2X 네트워크에서는 차량이 주기적으로 송신하는 Cooperative Awareness Message(CAM)를 통해 주변 차량 및 인프라와 위치, 속도, 방향 등의 정보를 실시간으로 교환한다. 하지만 최근 내부 공격자가 올바른 인증키를 이용해 허위 CAM 정보를 전송하는 메시지 변조 공격(CAM falsification attack) 사례가 부각되면서, 암호학적 무결성만으로는 대응하기 어려운 새로운 위협이 제기되고 있다. 이러한 공격은 차량의 실제 위치나 속도와 일치하지 않는 데이터를 전송함으로써, 교통 흐름을 교란하거나 사고를 유발할 수 있다.

본 연구는 CAM 메시지의 변조 공격을 비지도 학습 기반으로 탐지하는 경량 이상탐지 모델을 설계하고, 이를 통해 5G/6G 기반의 V2X 환경에서의 적용 가능성과 한계를 실험적으로 검증하였다.

이를 위해, 실제 도로 환경에서 수집된 5G기반의 V2AIX[2] 데이터셋을 정상 주행 학습용으로 활용하고, 802.11p 기반 시뮬레이션 데이터셋인 VeReMi[1]를 검증 및 평가용으로 활용하여 탐지 성능을 정량적으로 분석하였다.

2. 관련 연구

Cao 등[3]은 메시지 시퀀스를 그래프 구조로 모델링하고 Transformer 기반으로 국소 및 전역의 시공간 특징을 결합하는 IoVST 기법을 제안하여 CAM 변조 탐지 정확도를 기존 CNN-LSTM 기반 모델보다 향상시켰다. Tsukada 등[4]은 CAM 단독 검증의 한계를 보완하기 위해 Collective Perception Message(CPM)를 CAM 검증 과정에 활용하여 위조 메시지 탐지 성능을 개선하였다.

하지만 기존 연구들은 주로 동일한 통신 기술 환경에서 수집된 데이터로 학습과 평가를 수행하였다는 한계가 존재한다[5]. 본 연구에서는 5G 기반 실세계 데이터셋(V2AIX)으로 학습을 수행하고, IEEE 802.11p(DSRC/ITS-G5) 기반 시뮬레이션 데이터셋(VeReMi)으로 평가를 진행함으로써, 통신 기술의 차이를 넘어 CAM 변조 탐지가 가능함을 보인다.


3. 연구 방법

3.1. DSRC (IEEE 802.11p) vs C-V2X (5G)

그림1은 기존의 V2X 통신인 IEEE 802.11p 기반의

DSRC(ITS-G5)와 3GPP Release 16~18을 기반으로 한 5G-V2X 방식의 프로토콜 스택을 보여주는 그림이다.

물리(MAC/PHY) 계층과 무선 접속 방식에서는 차이를 보이지만, 그 상위 계층인 Facility 및 Network 계층에서는 공통적으로 ETSI 표준을 따른다. 즉, CAM, DENM 등의 메시지는 동일한 형식과 구조를 가지게 된다. 이러한 구조적 공통성 덕분에, 통신 기반이 다르더라도 CAM 메시지 포맷은 플랫폼 간 호환이 가능하다.



(그림 1) DSRC(ETSI), 5G-V2X 간의 Protocol Stack 비교

3.2. 데이터셋 및 전처리

(표 1) V2AIX/ VeReMi 데이터셋 전처리

파라미터	V2AIX	VeReMi	통일 단위
timestamp	recording_times tamp_nsec(ns)	sendTime(s)	second
station_id	station_id	sender	ID
pos_x, pos_y, pos_z	longitude/latit ude(degree)	pos[0], pos[1], pos[2]	meter
speed	speed_value (m/s)	$\sqrt{spd_x^2 + spd_y^2}$	m/s
heading	heading_value	$\arctan(spd_x, spd_y)$	degree
spd_x, spd_y, spd_z	speed*cos/sin (heading)	spd[0], spd[1], spd[2]	m/s
scenario_id	시나리오 명	시나리오 명	문자열 ID
dpos_x, dpos_y	인접 시점 좌 표간 차이	인접 시점 좌표 간 차이	meter
attacker_type /is_attacker	-	attacker_type	정수형

표 1은 단위 정규화에 사용된 변환 방식 및 통일된 파라미터 단위와 CAM 메시지에서 추출한 주요 파라미터이다.

이 파라미터들은 학습 안정성을 위해 V2AIX 데이터 기반으로

학습된 StandardScaler를 이용해 정규화하여 VeReMi 데이터에도 일관적으로 적용하였다. 시계열 예측 기반 AutoEncoder 모델에 적합한 입력과 시계열 데이터 증강을 위해 sliding window 방식으로 시퀀스를 생성하여, 입력 시퀀스는 연속된 5개 시점의 데이터로 구성되며, 예측 대상은 다음 1개 시점의 데이터이다.

3.3. 모델 구조 및 학습 방법

본 연구에서는 시계열 예측 AutoEncoder (Prediction-AE) 구조를 사용하였다. 구체적으로, 입력 시퀀스는 CAM 메시지 기반의 8개 피쳐(pos_x, pos_y, pos_z, speed, heading, curvature, dpos_x, dpos_y)로 구성된 5개의 연속된 시점이며, 출력은 다음 시점의 동일한 8차원 벡터이다.


모델은 2개의 LSTM 계층(hidden dim=128)과 Dropout(0.3)을 포함하며, 출력은 마지막 LSTM 상태를 기반으로 생성된다. 손실 함수는 예측값과 실제값 간의 평균제곱오차(MSE)를 사용하였다. 학습은 V2AIX 데이터셋으로부터 추출한 정상 시퀀스를 기반으로 수행되었으며, 학습 파라미터는 Epoch 50, Batch size 128, 학습률 0.001로 설정하였다.

3.4. 실험 및 평가


학습된 Prediction-AutoEncoder 모델은 VeReMi 데이터셋을 이용하여 테스트하였다. 각 시퀀스에 대해 모델은 다음 시점의 피쳐 벡터를 예측하고, 실제 값과의 평균제곱오차(MSE)를 기반으로 재구성 오차를 계산한다. 이 재구성 오차는 이상 탐지 점수로 활용되며, 공격 여부 판단을 위한 임계값(threshold)은 Precision 보다 Recall을 더 중시하는 환경을 고려하여 Precision-Recall 곡선 상의 F2-score를 최대화 하는 지점을 탐색하여 설정하였다.

3.5. 실험 결과

그림 2, 3은 정상 CAM 메시지와 공격 메시지의 예측 오차(MSE) 분포를 로그 스케일로 시각화한 그래프이다. 두 공격 유형 모두에서 재구성 오차가 명확히 분리되는 경향을 볼 수 있다.



(그림 2) Random Position 공격 유형 예측 오차(MSE) 분포



(그림 3) Random Offset 공격 유형 예측 오차(MSE) 분포

표 2는 Random Position 및 Random Offset 공격 유형에 대해 각 시나리오별로 평균을 낸 이상 탐지 성능 결과이다. 두 공격 유형 모두 높은 탐지 성능을 보인다. 특히 Random Position 공격은 Precision, Recall, F1-score가 거의 1.0에 근접하여 정탐과 오탐 모두에서 매우 우수한 성

능을 확인할 수 있다.

(표 2) 공격 유형별 이상 탐지 성능 결과

Attack Type	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
Random Position	0.9982	0.9998	0.9973	0.9999	0.9997
Random Offset	0.9793	0.9904	0.9822	0.9992	0.9970

이는 Random Position 공격이 모델의 예측 오차를 크게 증가시키므로, 정상 데이터와의 재구성 오차 분포 차이가 뚜렷하기 때문이다. 반면, Random Offset 공격은 위치 변조 범위가 오프셋으로 제한되기 때문에 일부 영역에서 정상과 분포가 겹치는 구간이 존재하여, 이에 따라 Precision은 상대적으로 소폭 감소한 것으로 분석된다. 또한 ROC-AUC 및 PR-AUC 값이 각각 0.99 이상을 유지하고 있어, 모델이 두 공격 유형에 대해 안정적이고 효과적인 탐지 성능을 제공함을 알 수 있다.

4. 결 론

본 연구는 5G-V2X 환경에서의 이상행위 탐지를 목표로, CAM 메시지 기반의 시계열 예측형 AutoEncoder 모델을 제안하고 실험적으로 평가하였다. 학습에는 실제 5G 통신 기반으로 수집된 V2AIX 정상 데이터를, 테스트에는 IEEE 802.11p 시뮬레이션 기반의 VeReMi 공격 데이터를 사용하였다. 실험 결과, 제안한 Prediction-AutoEncoder는 VeReMi 데이터셋의 공격 유형 중 Random Position attack과 Random Offset attack에 대해 높은 탐지 성능을 기록하였다.

5G 기반 실측 데이터와 IEEE 802.11p 기반 시뮬레이션 데이터를 함께 활용하여 효과적인 탐지 성능을 입증하였다는 점에서, 본 모델은 5G-V2X를 넘어 향후 6G-V2X 환경에서도 CAM 메시지를 기반으로 확장 적용이 가능할 것으로 기대된다.

이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구입니다. (No.RS-2024-00444170, 6G 개방형 네트워크 환경에서 트러스트 모델 기반 지능형 침해 대응 기술 연구 및 국제협력)

참 고 문 헌

- [1] Rens W. van der Heijden, Thomas Lukaseder, Frank Kargl, "VeReMi: A Dataset for Comparable Evaluation of Misbehavior Detection in VANETs," SecureComm 2018, pp.318-333, 2018.
- [2] Guido Kueppers, Jean-Pierre Busch, Lennart Reiher, Lutz Eckstein, "V2AIX: A Multi-Modal Real-World Dataset of ETSI ITS V2X Messages in Public Road Traffic," arXiv preprint, arXiv:2403.10221, 2024.
- [3] Jinhui Cao, Xiaoqiang Di, Jinqing Li, Keping Yu, Liang Zhao, "IoVST: An Anomaly Detection Method for IoV based on Spatiotemporal Feature Fusion," Future Generation Computer Systems, vol.166, Article ID: 107636, 2025.
- [4] Manabu Tsukada, Shimpei Ariei, Hideya Ochiai, Hiroshi Esaki, "Misbehavior Detection Using Collective Perception under Privacy Considerations," arXiv preprint arXiv:2111.03461, 2021.
- [5] 남강현, "취약한 도로사용자와 자율주행 셔틀 차량 연동 5G V2X 기능 연구," 정보기술융용연구, 제32권 제3호, pp.19-34, 2025.