RAG-PoisonMatch: 생성 매칭 RAG 포이즈닝 탐지 데이터셋 구축 및 공격 유효성 검증

최동진[1], 차한솔[2], 김민규[2], 김종현[2]
[1]세종대학교 사이버국방학과, [2]세종대학교 정보보호학과
e-mail : dongpoit@sju.ac.kr

RAG-PoisonMatch: A Generation-Matched Dataset for RAG Poisoning Detection and Attack-Efficacy Validation

Dongjin Choi, Cha Hansol, Mingyu Kim, Jonghyun Kim

1. 서 론

검색증강생성(Retrieval-Augmented Generation, RAG)은 외부 지식베이스의 관련 문서를 검색해 생성 모델의 입력으로 활용함으로써 지식을 보완한다. 그러나 공격자가 지정 오답을 지지하는 문서를 지식베이스에 삽입하면 해당 문서가 검색되어 최종 응답까지 오염될 수 있다[1]. 이에 RAG 포이즌 문서를 식별·차단하기 위한 탐지 방법이 제안되고 있다[2].

기존 공격 자료를 탐지 데이터로 재사용하면 포이즌 문서와 정상 문서의 생성 출처 차이가 탐지 단서로 작용할 수 있다. 이에 본 연구는 다음 세 가지를 수행한다. 첫째, 동일한 표적·참조 원문·생성기·생성 조건에서 포이즌 문서와 대조 문서를 대응 생성한 RAG-PoisonMatch consensus336을 구축한다. 둘째, 표면 특징과 학습 기반 모델을 이용해 생성 출처가 통제된 조건의 탐지 난이도와 잔존 학습 신호를 평가한다. 셋째, Natural Questions[4] 기반 NQ100k에 포이즌 문서를 삽입하여 검색 노출과 응답 오염을 측정함으로써 공격 유효성을 검증한다.

2. 관련 연구

PoisonedRAG는 악성 문서를 지식베이스에 삽입하여 검색 노출과 지정 답변 생성을 유도하는 RAG 포이즈닝 공격을 제안하였다[1]. GMTP는 이러한 포이즌 문서를 검색 단계에서 식별하기 위한 탐지 방법을 제안하였다[2]. 그러나 기존 공격 자료를 탐지 데이터로 재사용하면 LLM이 생성한 포이즌 문서와 사람이 작성한 정상 문서가 비교된다. 탐지 모델이 포이즈닝 의미보다 생성 출처에 따른 문체와 표면 특징을 학습할 가능성이 있다.

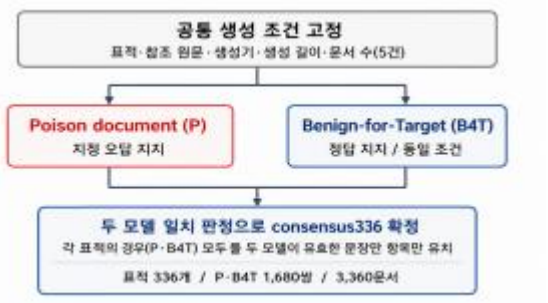
본 연구에서 TF-IDF 기반 로지스틱 회귀를 통해 기존 비매칭 자료의 코퍼스 기반 분류 성능을 재분석 해봤을 때, AUROC 0.966 - 0.986으로 데이터 생성 출처의 영향이 큰 것으로 확인되었다. 이에 본 연구는 포이즌 문서와 대조 문서를 동일 생성기·참조 원문·생성 조건에서 대응 생성하여, 생성 출처를 통제한 상태에서 포이즈닝 의미에 따른 탐지 가능성을 평가한다.

3. 연구 방법

RAG-PoisonMatch는 위협 모델 정의, 생성 매칭 P/B4T 구성, 두 모델 합의에 의한 의미 유효성 검수의 세 단계로 구축하였다. 전체 구축 과정은 그림 1과 같다. 질문과 관련되면서 지정 오답을 지지하고 정답을 지지하지 않는 문서를 포이즌 문서(Poison document, P)로 정의한다. 반대로 동일한 표적과 생성 조건에서 정답을 지지하고 지정 오답을 지지하지 않는 대조 문서를 Benign-for-Target(B4T)으로 정의한다.

3.1 위협 모델과 탐지 단위

본 연구는 공격자가 표적 질문과 지정 오답을 정하고, 해당 오답을 지지하는 문서 5건을 RAG 지식베이스에 삽입하는 상황을 가정한다. 공격자는 지식베이스에 문서를 삽입할 수 있으나 검색기와 생성 모델의 파라미터는 변경하지 않는 것으로 가정한다. 방어자는 문서 유입 시점에 개별 문서를 판정한다. B4T는 일반 정상 코퍼스가 아니라 탐지 평가용 대조 문서이며, 공격 유효성 평가용 지식베이스에는 삽입하지 않는다.



(그림 1) RAG-PoisonMatch 생성 매칭 및 두 모델 일치 판정 절차

3.2 생성 매칭 P/B4T 구성

의미 유효성 검수 전, P/B4T 후보군 494표적은 PoisonedRAG[1]의 NQ 표적 중 P/B4T 생성 결과가 확보된 base 97개와 Natural Questions test 질의[4]에서 확장한 expanded 397개로 구성하였다. base는 공개된 질문·정답·지정 오답을 그대로 사용했으며, expanded는 qrels 정답 근거 문서를 바탕으로 5단어 이하의 정답과 동일 유형의 지정 오답 후보를 생성한 뒤, 정답은 근거 문서에 포함되고 오답은 정답과 다르며 근거 문서에 나타나지 않는 경우만 유지하였다.

각 표적에 대해 Contriever[3] 검색 상위 3개의 질의 관련 문서를 선택하고, 이를 P와 B4T의 공통 참조 문서로 고정하였다. 이후 gemma4-26b에 동일한 프롬프트, temperature 1.0, 약 100단어의 생성 길이와 문서 수 5건을 적용하여 P는 지정 오답을, B4T는 정답을 지지하도록 생성하였다. 같은 순번의 P_i와 $B4T_i$를 대응 쌍으로 구성했으며, 두 조건에서는 지지 대상 답변만 변경하였다.

3.3 의미 유효성 검수와 데이터셋 확정

이들 494표적·2,470쌍의 의미 유효성을 고정된 gpt-oss:20b와 qwen3.6:35b-a3b로 검수하였다. 각 쌍은 P의 오답 지지·정답 비지지, B4T의 정답 지지·오답 비지지, 동일 주제, P와 B4T가 모두 자연스럽

고 두 문서의 문체가 비교 가능한 수준이어야 유효한 것으로 보았다.

두 모델 모두가 표적의 5쌍 전체를 유효하다고 판정한 경우에만 해당 표적을 유지했다. 한 쌍이라도 실패하면 표적 전체를 제외하고, 검수 후 문서 수정·재생성은 하지 않았다. 이에 158표적을 제외해 consensus336(1,680쌍·3,360문서)을 확정했다.

(표 1) 두 모델 일치 판정에 따른 데이터셋 규모 변화

구분	표적	쌍(문서)	선별 기준
후보	494	2,470 (4,940)	검수 대상
제외	158	790 (1,580)	5쌍 중 1쌍 이상 유효 조건 미충족
최종	336	1,680 (3,360)	두 모델 모두 5쌍 유효 판정

4. 평가 및 결과

4.1 평가 방법

consensus336은 동일 표적과 참조 원문이 분할 간 겹치지 않도록 train/dev/test 202/67/67표적으로 분할하고, test의 P/B4T 각 335건, 총 670문서에서 탐지 성능을 평가하였다. 탐지는 임베딩·이웃 구조 6종, 언어·표면 통계 8종, 추가 탐지 점수 2종(GMTP-F[2], NLI 모순 점수)의 16개 개별 특징과 TF-IDF+LR, DeBERTa-v3-base를 비교하였다.

임베딩 계열은 유사도·임베딩 노름·중심거리·Mahalanobis 거리 등을, 언어·표면 계열은 PPL 통계·문서 길이·어휘 다양성·문장 수·구두점 비율·생성문 판별 점수를 포함한다. TF-IDF+LR 및 DeBERTa는 train에서 학습하고 dev에서 설정을 선택한 뒤 test에서 최종 평가했으며, DeBERTa는 3개 seed의 예측 점수를 앙상블하였다. 임베딩·이웃 통계는 분할별·라벨 비인지 방식으로 계산하였다.

공격 평가는 Natural Questions[4] 기반 NQ100k에 consensus336 P 1,680건만 삽입하고 Contriever[3] top-5 문맥을 사용하였다. P/B4T 생성과 주 reader에는 동일한 Gemma 4-26B 모델을 사용하였다. 보조 평가에서는 검색 문맥과 프롬프트, 판정 기준을 유지한 채 reader만 Mistral Small 3.2-24B로 교체하였다.

4.2 평가 지표

탐지 성능은 AUROC로 평가하고, 방법 간 차이는 한 표적의 P/B4T 10문서를 함께 유지한 표적 단위 paired bootstrap 2,000회로 추정했다. 노출@5는 동일 표적 P가 상위 5개 문서에 포함된 비율이다. strict ASR은 응답에 지정 오답이 포함되고 정답은 포함되지 않은 비율이며, 검색 귀속 strict ASR은 여기에 동일 표적 P의 top-5 노출까지 요구한 비율이다. strict flip은 clean strict 정답이 공격 후 strict 오답으로 바뀐 비율이다.

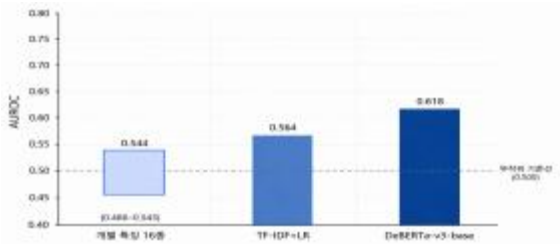
4.3 평가 결과

표 2와 같이, 동일한 Contriever top-5 문맥에서 same-target P 노출@5는 331/336(98.51%)이었다. Gemma 주 reader의 strict ASR은 303/336(90.18%)이었으며, 생성·선별에 관여하지 않은 Mistral 보조 reader에서도 292/336(86.90%, 95% CI 82.88–90.10%)이 관찰되었다. clean 조건에서 strict 정답인 표적 중 strict 오답으로 전환된 비율은 Gemma가 35/49(71.43%), Mistral이 49/60(81.67%)이었다. 두 flip 비율은 조건부 분모가 다르므로 직접적인 성능 우열로 해석하지 않는다. C52의 Mistral strict ASR은 우리 P 82.69%, 공식 P 80.77%(+1.92%p)였으며, ±0.10 TOST에서는 −10%p 비열등성만 확인되고 동등성은 성립하지 않았다.

(표 2) RAG-PoisonMatch 평가 결과

평가 항목	조건·지표	주요 결과
탐지	특징 16종 / TF-IDF+LR / DeBERTa	AUROC 0.486–0.544 / 0.564 / 0.618
전체 공격	노출@5 / strict ASR / 조건부 flip	98.51% Gemma 90.18%, 35/49 Mistral 86.90%, 49/60
C52	우리 P / 공식 P strict ASR	Gemma 78.85/75.00% Mistral 82.69/80.77% −10%p 비열등성만

그림 2와 같이 개별 특징 16종의 AUROC는 0.486–0.544으로 무작위 기준선 부근에 분포했으며, TF-IDF+LR과 DeBERTa-v3-base의 AUROC는 각각 0.564와 0.618이었다. 두 방법 간 차이는 미반올림 AUROC 기준 +0.053이었으며, 표적 단위 bootstrap 2,000회에서 차이의 95% 신뢰구간은 0.007–0.099였다. 이는 생성 조건을 일치시킨 consensus336에서 단순 특징만으로 P와 B4T를 구분하기 어렵지만, 일부 학습 가능한 신호는 남아 있음을 시사한다.



(그림 2) RAG-PoisonMatch의 탐지 방법별 AUROC 비교

본 연구의 기존 비매칭 자료 재분석에서는 TF-IDF+LR의 AUROC가 0.966–0.986이었던 반면, consensus336에서는 0.564로 나타났다. 두 평가는 단순 생성 출처 신호가 탐지 성능에 영향을 줄 수 있다는 문제의식을 뒷받침한다.

5. 결론

RAG-PoisonMatch consensus336은 P와 탐지용 B4T의 생성 조건을 일치시켜, 탐지 난이도와 잔존 학습 신호 및 실제 공격 유효성을 함께 평가한 데이터셋이다. RAG-PoisonMatch는 생성 출처를 통제한 조건에서 포이즈닝 탐지 모델이 의미적 차이를 학습하는지를 비교하기 위한 평가 자료로 활용할 수 있다. 데이터셋은 논문 발표 후 데이터셋 카드·분할 정보·검수 기록과 함께 공개할 예정이다.

한계는 단일 생성기·검색기, 합의에 따른 후향 선별 편향, 단일 생성·선별 비관여 reader 평가, C52 한정 비교와 동등성 미확립이다.

Acknowledgement

이 논문은 2026년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구 결과임(No. RS-2026-25509873, 사이버공격 실시간 방어수준 계량평가 및 전주기 자율보안을 위한 시뮬레이터 개발).

참 고 문 헌

[1] W. Zou, R. Geng, B. Wang, and J. Jia, “PoisonedRAG: Knowledge Corruption Attacks to Retrieval-Augmented Generation of Large Language Models,” in Proc. of 34th USENIX Security Symposium, pp.3827-3844, 2025.

[2] S. Kim, J. Kim, Y. Jeon, and G. Lee, “Safeguarding RAG Pipelines with GMTP: A Gradient-based Masked Token Probability Method for Poisoned Document Detection,” in Proc. of Findings of ACL 2025, pp.24597-24614, 2025.

[3] G. Izacard, M. Caron, L. Hosseini, et al., “Unsupervised Dense Information Retrieval with Contrastive Learning,” Transactions on Machine Learning Research, 2022.

[4] T. Kwiatkowski et al., “Natural Questions: A Benchmark for Question Answering Research,” Transactions of the Association for Computational Linguistics, vol.7, pp.452-466, 2019.