

5G/6G C-ITS 환경에서의 차량 수준 평가 기반 Prediction-AE CAM 변조 공격 탐지 모델 연구*

김 준 식,^{1†} 서 예 린,¹ 김 민 규,² 김 종 현^{3‡}
^{1,2,3}세종대학교 (학생, 대학원생, 교수)

A Study on a Prediction-AE Based CAM Falsification Attack Detection with Vehicle-Level Evaluation*

Jun-sik Kim,^{1†} Ye-rin Seo,¹ Min-gyu Kim,² Jong-hyun Kim^{3‡}
^{1,2,3}Sejong University (Undergraduate, Graduate student, Professor)

요 약

5G/6G 차세대 지능형 교통 시스템에서 CAM은 차량 간 주행 상태를 주기적으로 공유하여, 실시간 상황 인지와 충돌 방지를 가능하게 하며, CAM의 신뢰성을 보장하는 것은 교통안전 확보의 핵심이다. 본 연구는 Prediction AutoEncoder를 활용하여 V2X 환경의 CAM 변조 공격 탐지를 수행하였다. 정상 주행 데이터셋(V2AIX)로 학습된 모델을 IEEE 802.11p 기반 시뮬레이션 데이터셋(VeReMi Extension)에 적용하였다. 실험 결과, 메시지 수준에서는 노이즈와 주행 변동성으로 인해 상대적으로 높은 오탐·미탐이 발생했으나, 차량 단위 집계 방식을 도입하여 이러한 한계를 완화할 수 있었다. 또한 서로 다른 무선 기술에서 수집된 데이터로 학습·평가가 이루어졌음에도 일정 수준의 탐지 성능을 유지함을 보였으며, 이는 제안된 방법이 통신 세대 간 일반화 가능성과 5G-V2X를 넘어, 향후 6G-V2X 환경으로의 확장성을 동시에 지님을 보여준다.

ABSTRACT

Cooperative Awareness Messages (CAM) convey driving states to nearby vehicles and roadside infrastructures. This real-time information enables situational awareness and collision avoidance. This study presents a Prediction AutoEncoder-based approach for detecting CAM falsification attacks in V2X environments. The model was trained using the real-world 5G-V2X dataset (V2AIX) and evaluated on the IEEE 802.11p-based simulation dataset (VeReMi Extension). Results showed that message-level detection was prone to false positives and false negatives due to noise and driving variability. However, applying a station-level aggregation approach effectively mitigated these issues. Despite being trained and tested on datasets collected from different wireless technologies, the model maintained consistent detection performance. This demonstrates that the proposed method possesses both generalizability and scalability beyond 5G-V2X, extending to future 6G-V2X environments.

Keywords: Cooperative Awareness Message(CAM), 5G/6G C-ITS, V2X, anomaly detection, AutoEncoder

I. 서론

차량 간 통신(Vehicle-to-Everything, V2X)은 자율주행과 지능형 교통 시스템(ITS)의 핵심 요소로, 도로 안전성과 교통 효율성을 향상에 이바지하고 있다. 특히 V2X 네트워크에서는 차량이 주기적으로 송신하는 Cooperative Awareness Message(CAM)를 통해 실시간으로 주변 차량 및 인프라와 위치, 속도, 방향 등의 정보를 교환하여, 차량과 교통 인프라 간 실시간 상황 인식을 지원한다.

하지만 최근 공격자가 합법적인 인증키를 이용해 허위 CAM 정보를 전송하는 메시지 변조 공격(CAM falsification attack) 사례가 주목받으면서, 암호학적 무결성만으로는 대응하기 어려운 새로운 위협이 제기되고 있다. 이러한 공격은 차량의 실제 위치나 속도와 일치하지 않는 데이터를 전송함으로써, 차량 흐름을 교란하거나 사고를 유발할 수 있다. 따라서 암호학적 방법론과 더불어, 데이터 기반 이상 탐지 기법이 요구되는 상황이다.

최근 V2X 통신은 기존의 IEEE 802.11p 기반의 Dedicated Short-Range Communications(DSRC)를 넘어, 5G 셀룰러 V2X(C-V2X) 기술로 빠르게 확산되고 있다. 5G는 초저지연(ultra-low latency), 고신뢰(high reliability), 대규모 연결(massive connectivity)이라는 특성을 바탕으로, 실시간 안전 메시지 교환과 자율주행 지원에 적합한 네트워크 인프라를 제공한다. 특히 5G New Radio-V2X(NR-V2X)는 보다 높은 주파수 대역과 네트워크 슬라이싱, 모바일 엣지 컴퓨팅(MEC)과의 결합을 통해 DSRC 대비 안정적이고 확장성 있는 서비스를 가능하게 한다. 나아가 6G 시대에는 초정밀 위치 측정과 테라헤르츠(THz) 통신 등 새로운 기능이 추가될 것으로 예상된다. 그러나 이러한 고도화된 네트워크에서도 CAM 변조 공격과 같은 내부 위협은 여전히 잠재적 위협으로 남는다.

CAM 메시지는 ETSI 표준(EN 302 637-2)에 의해 정의되어 있다. CAM은 원래 DSRC/ITS-G5 환경을 위해 설계되었지만, 표준 구조가 유지되기 때문에 5G 및 6G 기반 C-V2X 환경에서도 활용될 것으로 예상된다. 이는 곧, CAM 변조 공격이 특정 무선 전송 기술에 국한되지 않고 차세대 V2X 환경 전반에서 동일하게 발생할 수 있음을 의미한다.

본 연구의 목표는 5G 기반 환경에서 수집된 정상 CAM 정보를 활용하여 다른 도메인인 DSRC 환경

에서 발생 할 수 있는 CAM 변조 공격을 탐지할 수 있는 탐지 모델을 구축하는 데 있다. 이를 위해 실제 5G 기반 환경에서 수집된 V2AIX 정상 데이터를 학습 데이터로 활용하고, DSRC 기반 VeReMi Extension 데이터셋의 공격 시나리오를 평가에 적용하여 cross-domain 일반화 성능을 검증한다 [1][2]. 이를 통해 제안 모델이 다양한 V2X 환경에서 실효성을 실험적으로 확인하고, 차세대 C-ITS 보안 프레임워크 설계에 이바지하고자 한다.

II. 배경 및 관련 연구

2.1 CAM 메시지의 구조와 위험

C-ITS는 차량과 도로 인프라, 보행자, 네트워크 간의 협력적 통신을 기반으로 교통 안전성과 효율성을 향상하는 차세대 지능형 교통 체계이다.

ETSI와 IEEE는 이를 위해 Cooperative Awareness Message(CAM) 및 Basic Safety Message(BSM) 표준을 정의하였으며, 각 차량은 주행 중 주기적으로 CAM을 브로드캐스트하여 위치, 속도, 진행 방향 등 상태 정보를 주변에 공유한다. 이러한 구조는 운전자와 자율주행 시스템이 센서의 가시 범위를 넘어 주변 상황을 인식할 수 있도록 지원한다.

C-ITS는 Public Key Infrastructure(PKI) 기반 인증 체계를 통해 메시지 발신자의 신원과 서명을 확인할 수 있다. 그러나 이러한 절차는 메시지가 실제 주행 정보를 반영하는지 여부, 즉 내용적 정확성을 보장하지는 않는다. 합법적 키와 인증서를 보유한 차량이 허위 위치나 속도 정보를 담은 CAM을 전송할 경우, 수신 측은 이를 정상 메시지로 신뢰할 수밖에 없어 차량 흐름 교란이나 충돌 사고로 이어질 위험이 존재한다.

2.2 오용 탐지 시스템 및 기존 연구 동향

이러한 내부 위협에 대응하기 위해 Misbehavior Detection System(MDS)이 제안되었다. MDS는 수신한 메시지의 내적 일관성과 물리적 타당성을 검증하여 공격 여부를 판별하는 기법으로, Sybil, 위치 변조, Replay와 같은 대표적 공격을 주요 탐지 대상으로 다룬다.

초기 연구들은 주로 규칙 기반 검증에 의존했으

나, 이러한 접근은 고정된 조건에 의존하기 때문에 다양한 교통·무선 환경에서 일반화가 어렵다는 한계가 있었다. 이에 따라 최근에는 데이터 기반 탐지 기법이 활발히 연구되고 있으며, 지도 학습(SVM, Random Forest 등)뿐 아니라 비지도 학습(AutoEncoder, K-means 등)과 딥러닝(LSTM, CNN 등)이 적용되고 있다[3].

Cao 등[4]은 메시지 시퀀스를 그래프 구조로 모델링하고 Transformer 기반으로 국소 및 전역의 시공간 특징을 결합하는 IoVST 기법을 제안하여 기존 CNN·LSTM 기반 모델보다 CAM 변조 탐지 정확도를 높였다.

또한 CAM 단독 검증의 한계를 극복하기 위해 ETSI가 정의한 Collective Perception Message (CPM)를 CAM 검증 과정에 활용하는 연구도 제안되었다[5]. Tsukada 등은 CPM 정보를 이용한 상호 검증들을 통해 CAM 변조 공격의 탐지율을 향상시키고 false positive를 감소시켰음을 보고하였다[6]. 하지만 기존 연구들은 주로 동일한 통신 환경(DSRC 혹은 5G V2X)에서 수집된 데이터로만 학습과 평가를 수행하였다. 본 연구에서는 다른 통신 환경에서의 데이터로 학습과 평가를 수행하여 이를 보완하고자 한다.

2.3 DSRC와 C-V2X의 프로토콜 스택 비교

Fig. 1.은 기존의 V2X 통신인 IEEE 802.11p 기반의 DSRC(ITS-G5)와 3GPP Release 16~18을 기반으로 한 5G-V2X 방식의 프로토콜 스택 구조를 비교한 그림이다.

DSRC의 경우 물리/무선 접속 계층은 IEEE 802.11p PHY와 IEEE 802.11p MAC을 기반으로

하며, 네트워크 계층은 Geo Networking과 IPv6, TCP/UDP를 통해 메시지를 전달하며, Facilities 계층에서는 ETSI ITS 표준 메시지(CAM, DENM)를 제공한다.

반면, 5G-V2X는 PC5 side link 인터페이스를 통해 NR 기반 무선 자원에 직접 접근하며, PHY-MAC-RLC-PDCP로 이어지는 3GPP 프로토콜 스택을 따른다. 네트워크 계층은 IP 기반 통신과 Geo Networking 방식을 모두 지원하며, Facility 계층 또한 CAM, DENM을 포함한 ETSI ITS 표준 메시지를 제공한다.

이와 같이 DSRC와 5G-V2X는 무선 접속 계층에선 서로 다른 기술을 사용하지만, 상위 계층(Facility 및 네트워크/전송 계층)은 ETSI ITS 표준을 공통으로 준수하므로 CAM과 DENM은 통신 방식과 무관하게 동일한 메시지 형식과 구조를 가진다.

2.4 비지도 학습 기반 접근

기존의 Misbehavior Detection 연구는 지도 학습 기반 분류기를 주로 활용하였으나, 실제 환경에서는 공격 라벨을 충분히 확보하기 어렵다는 한계가 있다. 이러한 문제를 해결하기 위해 최근에는 비지도 학습 기반 이상 탐지 기법이 주목받고 있다. 정상 데이터만을 이용해 모델을 학습하고, 새로운 메시지의 재구성 오차나 통계적 편차를 기준으로 이상 여부를 판정하는 방식이다[6].

AutoEncoder(AE)는 대표적인 비지도 학습 기법으로, 입력 데이터를 저차원 잠재 공간으로 압축한 후 다시 복원하는 구조를 통해 정상 데이터의 분포를 학습한다. 학습 시 정상 데이터만 사용하므로, 변조된 메시지와 같이 정상 분포에서 벗어난 입력은 재구성 오차(reconstruction error)가 크게 발생하며, 이를 통해 이상 행위를 탐지할 수 있다.

AutoEncoder 모델은 공격 데이터 라벨이 없어도 학습할 수 있으며, 알려지지 않은 새로운 공격 유형(Zero-day attack)에 대해서도 일정 수준의 탐지가 가능하다는 장점이 있다.

MEC 연동과 네트워크 성능 최적화를 위해 LSTM 기반 트래픽 예측을 활용한 연구가 보고되었다[7]. 하지만 해당 연구는 주로 전송 지연 등 네트워크 운용 최적화에 초점을 두고 있다. 하지만 CAM 메시지 변조를 대상으로 한 연구는 진행되지 않았다.

본 연구에서는 Prediction-AutoEncoder 구조




Fig. 1. Difference between DSRC(ETSI), 5G-V2X Protocol Stack

를 CAM 변조 탐지에 적용하여, 정상 주행 데이터에서 시계열 패턴을 학습하고, 이후 도메인이 다른 환경에서 수집된 메시지를 입력으로 주어 재구성 오차 대신 예측 오차(prediction error)를 활용함으로써, 기존 AutoEncoder 대비 CAM 변조 공격에 대한 탐지 정밀도와 안정성을 향상하고자 한다.

III. 연구 방법

3.1 데이터 셋

3.1.1 데이터셋 설명

본 연구는 학습과 평가를 위해 서로 다른 환경에서 수집된 두 데이터셋을 사용하였다. 학습에는 실제 5G 기반 환경에서 수집된 V2AIX 데이터셋을 사용하였으며, 평가는 IEEE 802.11p 기반 시뮬레이션 데이터셋인 VeReMi Extension을 사용하였다.

VeReMi Extension 데이터셋은 Kamel 등이

DSRC 기반 차량 통신 환경을 시뮬레이션하여 수집한 VeReMi[8] 데이터 셋을 확장하여 공개한 데이터셋으로, 센서 노이즈 모델을 추가하고, 더 다양한 공격 시나리오를 포함한다. 명확한 라벨과 다양한 공격 시나리오를 제공한다는 점에서 탐지 모델의 성능 평가에 적합하다. 하지만 시뮬레이션 기반 데이터라서 실제 환경에서의 특성을 충분히 반영하지 못한다는 한계가 있다.

V2AIX 데이터셋은 독일 아헨(Aachen) 지역에서 실제 도로 주행 환경을 기반으로 수집된 다중 모달 데이터셋이다. 해당 데이터셋은 ETSI ITS 표준 메시지(특히 CAM)를 중심으로, GNSS/INS, 카메라, 라이다 등 고정밀 센서 데이터를 함께 제공하며, 도심·교외·고속도로 환경을 포괄한다. 이를 통해 실제 C-V2X 무선 환경이 반영된 정상 주행 패턴을 학습할 수 있다.

따라서 본 연구에서는 V2AIX를 학습 데이터로, VeReMi를 평가 데이터로 활용하였다. ETSI CAM 메시지는 DSRC와 C-V2X 모두에서 동일한 구

Table 1. Attacker Type in VeReMi Extension

Type	Description	Sequence
Normal	Normal driving behavior	165,373
Constant position	Sends a fixed position repeatedly	3,804
Constant position offset	Sends position with a fixed offset added/subtracted from true position	3,793
Random position	Replaces position field with random coordinates	3,821
Random position offset	Sends position with a random offset applied to true position	3,701
Constant speed	Sends a constant speed value repeatedly (speed inconsistent with movement)	3,623
Constant speed offset	Sends speed with a fixed offset added/subtracted from true speed	3,886
Random speed	Replaces speed field with random values	3,662
Random speed offset	Sends speed with a random offset applied to true speed	3,705
Disruptive	Randomly replays messages from multiple vehicles to flood the network	3,776
Data replay	Replays past (legitimate) messages from other vehicles (data replay)	3,870
DoS	Increases transmission frequency beyond network limits to cause service denial	12,564
DoS random	Variant of DoS with randomized transmission patterns	12,103
DoS disruptive	Combination of DoS and disruptive replay flooding	12,370
Traffic congestion	Attack causing traffic/flow manipulation (congestion)	3,876

Table 2. Input features

Feature	Description	Unit
pos_x	Vehicle x-coordinate	m
pos_y	Vehicle y-coordinate	m
pos_z	Vehicle z-coordinate	m
spd_x	Speed component along x axis	m/s
spd_y	Speed component along y axis	m/s
spd_z	Speed component along z axis	m/s
speed	Scalar ground speed (magnitude)	m/s
heading	Heading / yaw angle	degrees
acl_x	Acceleration x component	m/s ²
acl_y	Acceleration y component	m/s ²
acl_z	Acceleration z component	m/s ²
dpos_x	Delta position in x since previous frame	m
dpos_y	Delta position in y since previous frame	m

조를 유지하기 때문에, 서로 다른 통신 환경에서 수집된 데이터 간에도 학습·평가가 연속적으로 적용할 수 있다. 이를 통해 본 연구는 5G 기반 데이터로 학습한 모델이 DSRC 기반 환경에서도 적용될 수 있음을 확인하고자 한다.

3.1.2 VeReMi extension 공격 유형

본 연구에서는 Alladi et al.의 연구에서 Kaggle에 공개되어있는 VeReMi Extension 기반 데이터셋(VeReMi Extension Simple)을 사용하였다 [9]. 이는 VeReMi Extension의 Ground Truth와 원시 로그를 결합하여 데이터셋을 구성하였으며, 해당 데이터셋에서 분류하는 주요 공격 유형은 Table 1.과 같다. 이 중 Sybil 계열 공격은 가짜 인증서를 기반으로 하므로, 해당 정보를 포함하지 않는 V2AIX 학습 데이터와의 호환성을 고려하여 분석에서 제외하였다.

3.2 실험 방법

Fig. 2.는 실험의 전체 흐름을 나타낸다. 정상 주행 데이터셋(V2AIX)과 공격 시뮬레이션 데이터셋(VeReMi)을 기반으로 특징 추출과 정규화, 시퀀스 생성을 거쳐 학습·검증·테스트 데이터를 구성하였다. 이후 Prediction-AE 모델을 학습하고, Percentile 및 F2-score 최적화 방식을 통해 임계값을 산정하여 메시지 수준 및 차량(station) 수준 평가를 통해 탐지 성능을 검증하였다.

3.3 전처리

3.3.1 모델 입력 피쳐 선정

CAM 메시지로 표현되는 차량의 물리·동역학 정보를 최대한 활용하기 위하여 Table 2.에 있는 13개의 피쳐를 입력으로 선정하였다. dpos_x, dpos_y는 인접 프레임 간 위치 변화량으로 계산되며 급격한 궤적 변화를 포착하기 위해 포함하였다.

3.3.2 단위·좌표 정규화 및 데이터 분할

서로 다른 좌표계·단위를 사용하는 두 데이터셋을 통합하여 학습·평가를 수행하므로, 도메인 불일치를 줄이기 위한 단위 통일 및 정규화를 적용하였다.

좌표계 통일을 위해서 V2AIX의 GPS(위도/경도) 기반 좌표를 로컬 직교 좌표계(미터 단위)로 변환하고, VeReMi의 시뮬레이션 좌표계는 동일한 미터 단위의 로컬 좌표계에 대응하도록 스케일링 및 매핑하였다.

단위 통일을 위해서는 모든 물리량(위치, 속도, 가속도 등)은 일관된 SI 단위(m, m/s, m/s² 등)로 표현되도록 정규화하였다.

또한 학습 데이터(V2AIX)에서 산출한 표준화 파라미터(평균·표준편차)를 저장하여 동일한 StandardScaler를 VeReMi 평가 데이터에 적용하여 스케일 차이에 따른 분포 이동을 최소화하였다.

3.3.3 시퀀스 생성

모델 입력은 시계열 윈도우 형태로 구성되며, 입력 윈도우 길이(window size)는 5, 예측 길이(pre_len)는 1로 설정하였다. 모델의 시퀀스 길이(L)




Fig. 2. Experience Work Flow

은 {5,10,15,20} 중 검증 데이터셋에서의 재구성 손실이 가장 안정적으로 나왔던 5로 설정하였고, 예측 길이는 1로 고정하였다.

구체적으로 각 시나리오 ID와 sender ID를 기준으로 시간 정렬된 메시지들로 길이 L 의 윈도우를 생성하고, 윈도우의 바로 다음 시점 값을 예측 대상으로 정한다. 즉 임의의 시점 t 에 대한 모델의 입력은 $X_{t-L+1:t} = [x_{t-L+1}, \dots, x_t]$ 이며 손실은 다음 시점 x_{t+1} 와 예측 $\hat{x}_{t+1}$ 간 MSE로 정의된다. 시퀀스 생성 및 데이터 증강을 위해 sliding window를 적용하였고, 윈도우 길이 미만의 시퀀스는 실험의 일관성을 위해 제거하였다.

3.4 모델 학습

3.4.1 Prediction AutoEncoder 모델

Prediction-AE는 입력 시퀀스의 재구성(reconstruction) 대신 다음 시점을 예측하도록 학습되는 시계열 예측 기반 AutoEncoder이다. 이러한 예측 기반 학습은 시간적 일관성을 직접 모델링하여, 입력

시퀀스의 재구성을 목표로 하는 전통적인 AE와 달리, CAM의 위치, 속도 등이 변조되었을 때 예측 오차가 많이 증가하여 이를 이상 점수(anomaly score)로 활용할 수 있다.

모델 구조는 입력 시퀀스를 선형 투영하여 고차원 표현으로 임베딩 후, Positional Encoding을 추가하여 순서 정보를 명시적으로 부여한다. 이후 2-layer LSTM 인코더를 통해 시간적 문맥을 압축하고, MLP 기반 디코더(Linear-ReLU-Dropout-Linear)에 전달하여 다음 시점 값을 직접 예측한다.

모델은 정상(V2AIX) 데이터만으로 MSE 손실을 최소화하도록 학습되었으며 테스트에서는 각 시퀀스의 next-step MSE를 이상 점수로 사용하였다. 학습 과정의 주요 하이퍼파라미터는 사전 실험을 통해 결정되었으며 Table 3.와 같다. 입력 차원은 13개의 피쳐를 사용하였다. 시퀀스 길이 $L=5$ 는 차량의 단기 동적 변화를 반영하면서도 모델 복잡도를 최소화하기 위해 설정하였다. 은닉 차원(128)과 Dropout(0.3)은 과적합을 방지하면서 충분한 표현력을 확보하기 위해 설정하였으며, Adam과 배치 크기 128은 학습 안정성을 고려하여 선택하였다. 또한 Early

Table 3. Parameter

Parameter	Value
Input dimension (d)	13
Sequence length (L)	5
Prediction length	1
Hidden dimension	128
Dropout rate	0.3
Optimizer	Adam
Batch size	128
Epochs	50
Early stopping	patience=10

Stopping은 정상 데이터 기반 학습 시 과적합 방지를 위해 적용하였다.

모델 학습 시 과적합 방지와 하이퍼파라미터 튜닝의 객관성을 확보하기 위하여, 학습 데이터(V2AIX)는 train/validation으로 분할하여 사용하였다. 분할 비율은 기본적으로 80%/20%(train/val)를 적용하였다. 분할은 senario 단위로 수행하여 학습 데이터와 검증 데이터 간에 동일 차량 시퀀스가 중복되어 검증 단계에서 이미 학습된 차량의 특성이 반영 데이터 누수를 차단하였다. 또한 검증 손실(validation MSE)을 기준으로 early stopping을 적용하였으며, patience는 10 epochs로 설정하였다. 즉, validation loss가 연속적으로 10 epoch 동안 개선되지 않으면 학습 중단 후, validation loss 최소 시점의 가중치를 기준으로 모델을 저장하였다.

3.5 임계값 설정 및 탐지 기준

3.5.1 메시지 수준 임계값 산정

모델이 산출하는 메시지 수준 이상 점수는 각 입력 시퀀스(원도우)의 마지막 프레임에 대응하는 메시지에 대한 다음 단계 MSE로 정의된다. 이 이상 점수를 바탕으로 두 가지 임계값 산정 방식을 비교 구현하였다.

Percentile 기반: 정상 데이터(V2AIX)에서 산출된 MSE 분포의 95th Percentile을 임계값으로 설정하였다. 테스트 시 개별 메시지의 MSE가 이 값을 초과하면 이상으로 판정한다.

F2 최적화 기반: VeReMi Extension을 validation set과 test set으로 2:8 비율로 분리하여,

validation set의 라벨을 활용하여 MSE 범위 내에서 후보 임계값을 탐색한 후, Precision과 Recall의 F2-score가 최대가 되는 지점을 임계값으로 설정하였다.

F2-score는 Precision과 Recall의 조화 평균에 있어서 Recall에 더 큰 가중치를 부여하는 지표이다. V2X 환경에서는 CAM 변조 공격은 누락 없이 탐지하는 것이 중요하므로, F2-score 기반 최적화가 적합하다. F2-score의 정의는 다음과 같다.

$$F_{\beta} = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{(\beta^2 \cdot \text{Precision}) + \text{Recall}}, \beta = 2 \quad (1)$$

3.5.2 차량 수준 탐지 기준

메시지 수준의 판정은 정상 주행의 자연스러운 변동성 및 센서 노이즈로 인해 오탐을 유발할 수 있다. 이를 완화하고, 여러 메시지에 걸쳐 누적되어 나타나는 공격을 보다 신뢰성 있게 검출하기 위해, 메시지-레벨 이상 플래그를 차량(station) 단위로 집계하는 방식을 적용하였다. 차량 수준 이상 판정은 두 가지 방식으로 정의하였다.

k/N voting: 메시지 수준에서 Percentile 기반 임계값으로 탐지한 결과를 집계하여, 최근 N개 메시지 중 k개 이상이 이상으로 판정되면 해당 차량을 공격 차량으로 분류한다. 본 연구에서는 N=20, k=5로 설정하였다. 파라미터는 N=20으로 고정 후, k를 {3,5,7,10} 가장 F1-score가 높게 나타난 k=5를 최종 값으로 채택하였다.

차량별 평균 오차 방식: 차량별 전체 메시지의 평균 MSE를 계산하여 이를 station-level 이상 점수로 활용하고, 라벨과 비교하여 Precision과 Recall의 F2-score가 최대가 되는 임계값을 선택하였다. 이 방식은 station-level에서 직접 최적 임계값을 산출함으로써, 메시지 수준 임계값의 누적 집계 방식과는 다른 관점을 제공한다. 다만 이는 성능 비교를 위한 실험적 가정이며, 실제 C-ITS 환경에서는 라벨이 존재하지 않기 때문에 비지도 기반 임계값 설정 기법이 필요하다.

3.5.3 평가 지표

본 연구에서는 제안한 Prediction-AE 기반 탐지 모델의 성능을 정량적으로 평가하기 위해 Table

Table 4. Performance Evaluation Metrics

Feature	Definition	Description
Accuracy	$\frac{TP+TN}{TP+TN+FP+FN}$	Ratio of correctly classified messages among all messages
Precision	$\frac{TP}{TP+FP}$	Proportion of detected anomalous messages that are truly attacks
Recall	$\frac{TP}{TP+FN}$	Proportion of true attack messages that are correctly detected
F1-score	$2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$	Harmonic mean of Precision and Recall

4. 와 같이 평가 지표를 사용하였다.

IV. 실험

4.1 실험 환경

본 연구의 Prediction-AE 기반 탐지 모델은 PyTorch 프레임워크를 사용하여 구현했으며, 학습 및 검증은 NVIDIA RTX 5070 Ti GPU(CUDA 지원 환경)에서 수행했다.

4.2 학습 결과

Figure 3.은 모델의 학습 및 검증 손실의 변화를 관찰한 그래프이다. 학습 과정에서 손실값은 초기 epoch 값부터 감소하면서 완만하게 수렴되었다. 특히 검증 손실의 변동 폭이 작고, 학습 손실과 차이가 일정하게 유지되어 모델이 과적합 없이 안정적으로 일반화되었음을 확인할 수 있다. 이는 모델이 입력 시퀀스의 패턴을 효율적으로 학습했음을 의미한다.




Fig. 3. Training and validation loss curves of the proposed Prediction-AutoEncoder.

4.3 실험 결과

4.3.1 공격 유형별 성능

Table 5.는 메시지 수준과 차량 수준 탐지 성능을 비교한 결과이다. 실험 결과, CAM의 위치 좌표 (pos_x, pos_y) 또는 메시지 시퀀스 패턴에 급격하고 비현실적인 변화를 초래하는 공격 유형들(Random Position / Random Position Offset / Data Replay / Traffic Congestion)에 대해서는 높은 Recall을 보이며 message-level과 station-level 모두에서 우수한 탐지 성능을 보였다. 이는 Prediction-AE가 위치와 이동 궤적 예측에 민감하게 학습되어 있기 때문에 큰 예측 오차가 발생하여 탐지가 가능함을 알 수 있다. 이 공격 유형들에 대한 성능은 모든 유형에서 높은 F1-score를 유지하였다.

DoS 계열(DoS, DoS_random 등) Random Speed, Random Speed offset과 같은 공격 유형들은 단일 메시지 수준에서는 정상 주행의 변동성과 쉽게 혼동되거나 순간적인 예측 오차가 작아 탐지가 어렵다. 그러나 개별 메시지의 노이즈를 완화하고, 누적된 비정상 패턴이 드러나면서 성능이 크게 향상되었다.

특히, DoS_random과 Random Speed의 경우 station level에서 차량 단위 평균 MSE를 이용한 방식을 적용할 경우, 메시지 수준 방식들과 k/N voting 방식에서 F1-score가 크게 개선되었다.

Figure 4.는 DoS_random 공격 유형에 대한 message level과 station-level 평가 간의 ROC-Curve와 PR-curve를 비교한 결과이다. 메시지 수준의 탐지 결과는 개별 CAM 메시지의 단기적인 노이

Table 5. Comparison of Detection Metrics (Message-level vs Station-level)

Attack Type (F1-s / Precision Recall / Accuracy)	Station N/k voting	Station mean error(F2)	Message Percentile	Message F2
Data Replay	0.976 / 0.969 0.982 / 0.977	0.994 / 0.997 0.990 / 0.994	0.940 / 0.942 0.937 / 0.944	0.928 / 0.904 0.955 / 0.932
Random	0.982 / 0.970	0.999 / 1.000	0.972 / 0.946	0.996 / 0.996
Position	0.995 / 0.983	0.997 / 0.999	1.000 / 0.973	0.997 / 0.997
Random	0.981 / 0.970	0.997 / 0.997	0.745 / 0.914	0.803 / 0.698
Position Offset	0.992 / 0.982	0.997 / 0.998	0.628 / 0.802	0.943 / 0.787
Traffic	0.980 / 0.970	0.994 / 1.000	0.950 / 0.980	0.941 / 0.916
Congestion	0.990 / 0.981	0.987 / 0.994	0.921 / 0.929	0.968 / 0.912
DoS	0.965 / 0.969 0.961 / 0.968	0.986 / 0.987 0.985 / 0.987	0.716 / 0.913 0.588 / 0.780	0.662 / 0.501 0.974 / 0.532
DoS Random	0.010 / 0.143 0.005 / 0.528	0.843 / 0.866 0.821 / 0.859	0.051 / 0.322 0.028 / 0.523	0.633 / 0.463 1.000 / 0.463
Random Speed	0.504 / 0.917 0.347 / 0.687	0.854 / 0.758 0.979 / 0.847	0.229 / 0.699 0.137 / 0.578	0.667 / 0.513 0.954 / 0.564
Random Speed Offset	0.967 / 0.991 0.945 / 0.966	0.998 / 0.998 0.998 / 0.998	0.693 / 0.905 0.562 / 0.771	0.806 / 0.806 0.794 / 0.783
Constant	0.030 / 0.333	0.628 / 0.459	0.083 / 0.444	0.636 / 0.466
Position	0.016 / 0.533	0.997 / 0.458	0.046 / 0.528	1.000 / 0.466
Constant	0.214 / 0.800	0.630 / 0.461	0.129 / 0.551	0.626 / 0.456
Speed	0.124 / 0.581	0.997 / 0.460	0.073 / 0.550	1.000 / 0.456
Disruptive	0.001 / 0.001 0.001 / 0.527	0.628 / 0.458 0.997 / 0.458	0.012 / 0.102 0.007 / 0.515	0.631 / 0.461 1.000 / 0.461
DoS Disruptive	0.015 / 0.200 0.008 / 0.527	0.631 / 0.462 0.997 / 0.461	0.034 / 0.487 0.018 / 0.269	0.844 / 0.730 1.000 / 0.730




Fig. 4. Comparison of (a) ROC and (b) Precision-Recall curves between message-level and station-level evaluations.

즈와 주행 편차에 직접 영향을 받기 때문에 매우 낮은 성능을 보였다. 하지만, 차량 단위 평균 MSE를 기반으로 한 station-level 집계 평가는 ROC-AU

C가 0.83, PR-AUC는 0.89로 상당히 높은 수치를 나타낸다. 이는 개별 메시지의 이상점이 일시적 환경 변화나 센서 노이즈로 인해 발생하더라도 차량 단위

평균화를 할 경우 노이즈가 완화되고 지속적 비정상 패턴만 부각되며, F2-score로 임계값 최적화 시 재현율(Recall)이 상대적으로 더 높게 유지되기 때문이다.

Constant Position/Offset, Random Speed Offset, Disruptive 등의 공격 유형은 전반적으로 낮은 탐지 성능을 보였다. 이러한 공격은 CAM의 위치·속도 일관성에는 큰 변화를 주지 않거나, 메시지 혼합·재생을 통해 네트워크 레벨에서만 이상을 유발하기 때문에 Prediction-AE의 시간적 궤적 기반 예측 모델로는 탐지에 한계가 있었다. 특히 Disruptive 공격 유형은 station-level 평균 MSE 방식을 적용했을 때 높은 Recall을 얻을 수 있었으나, Precision 크게 저하되어 오탐이 증가하는 한계가 있었다.

4.3.2 추론 시간 측정

Table 6은 제안 모델의 추론 성능을 정량적으로 평가한 결과를 나타낸다. 단일 CAM 시퀀스에 대한 평균 추론 지연은 0.38 ms로 측정되었으며, 이는 CAM 전송 주기(100ms) 대비 충분히 작은 값으로 실시간 처리 요구사항을 만족한다.

Table 6. Summary of Inference Performance

Item	Value
Accuracy	284,173 (0.28M)
Single-message inference latency (mean)	0.3837 ms
Single-message inference latency (95th percentile)	0.5640 ms
Batch processing latency (batch = 128)	0.0110 ms / sample

4.3.3 전체 성능 분석

Fig. 5.은 모든 공격 유형 중 11가지의 공격 유형 중 탐지율이 일정 수준 이상 측정된 공격 유형들에 대한 평균 성능 지표(Accuracy, Precision, Recall, F1-score)를 비교한 결과이다. 이는 모든 공격 유형을 평균에 포함할 경우, F1-score가 0에 근접하는 유형들이 전체 평균을 왜곡하는 문제가 발생하는 문제를 방지하고, 실제로 탐지할 수 있는 공격 유형에서의 상대적 성능을 보다 명확히 보여주기




Fig. 5. Average detection performance of 11 attack types

위함이다.

분석 결과 Station mean error(F2-score 최적화)는 Recall을 크게 향상하면서 Precision도 유지하여 가장 균형적인 성능을 보였다. 하지만, 이 방식은 실제 C-ITS 환경과 같이 라벨이 존재하지 않는 상황에는 직접 적용하기는 어려울 것으로 보인다. 실제 운용 환경에서는 정상 주행 구간의 오차 분포를 기반으로 한 비지도 임계값 설정 기법이 필요하다.

Message-F2의 경우, F1-Score가 상대적으로 높지만, Recall에 더 큰 가중치를 부여하는 F2-Score 특성상 Precision이 불균형적으로 낮게 나타나는 한계가 있었다.

또한 본 연구는 5G 기반 정상 데이터(V2AIX)로 학습하고 DSRC 기반 공격 데이터(VeReMi Extension)로 평가하는 cross-domain 구조를 가지므로, 성능 변화는 무선계층의 차이라기보다는 공격 시나리오와 라벨 분포의 특성에 크게 영향을 받는 것으로 나타났다.

V. 결 론

본 연구는 Prediction-AE 모델을 활용하여 V2X 환경에서의 CAM 변조 공격 탐지를 시도하였다. 5G-V2X 환경의 V2AIX 데이터셋의 정상 데이터를 학습하고, IEEE 802.11p 기반의 VeReMi Extension 데이터셋의 데이터를 평가에 활용하였다.

실험 결과, 메시지 단위 탐지에서는 변동성이 큰 공격(DoS, Random Speed 등)에서 성능 저하가 발생했으나, station-level 평균 MSE 방식 및 N/k voting 방식을 통해 탐지 성능이 크게 개선됨을 확인하였다. 특히, 위치·속도 시계열의 물리적 일관성 붕괴를 특징으로 하는 공격(Random Position, Data Replay)은 단일 메시지 수준에서도 안정적으

로 탐지할 수 있음을 보였다.

이러한 결과는 Prediction-AE가 시계열의 물리적 일관성 붕괴에 특히 민감함을 확인할 수 있으며, station-level 평가가 모델의 실질적 활용도를 높일 수 있음을 의미한다. 또한 서로 다른 무선 기술(5G-V2X, DSRC)에서 수집된 데이터로 학습, 평가가 이루어졌음에도 일정 수준의 성능을 보였다. 이는 서로 다른 무선 접속 기술임에도 상위 계층을 공유하듯이, 향후 6G-V2X에서도 동일한 상위 계층 표준을 유지하는 한 제한한 모델은 무선 기술 변화와 무관하게 재사용될 수 있다는 시사점을 보인다.

마지막으로 Disruptive, DoS_random 등 네트워크 레벨 특성이 강한 공격에 대해서는 메시지 기반 모델만으로 탐지에 한계가 있음을 확인하였으며, 향후 연구에서는 통신 품질 지표(RSSI, 패킷 손실률 등) 또는 규칙 기반 탐지와와의 결합을 통한 멀티모달 접근을 함께 고려해볼 필요가 있다.

References

- [1] G. Kueppers, J.-P. Busch, L. Reiher, and L. Eckstein, "V2AIX: A Multi-Modal Real-World Dataset of ETSI ITS V2X Messages in Public Road Traffic," *Proceedings of the 2024 IEEE 27th International Conference on Intelligent Transportation Systems (ITSC)*, pp. 392-398, Sep. 2024.
- [2] J. Kamel, M. Wolf, R. W. van der Heijden, A. Kaiser, P. Urien, and F. Kargl, "VeReMi Extension: A dataset for comparable evaluation of misbehavior detection in VANETs," *Proceedings of the 2020 IEEE International Conference on Communications (ICC)*, pp. 1-6, June. 2020.
- [3] A. Boualouache and T. Engel, "A Survey on Machine Learning-Based Misbehavior Detection Systems for 5G and Beyond Vehicular Networks," *IEEE Communications Surveys & Tutorials*, vol. 25, no. 2, pp. 1128-1172, Jan. 2023.
- [4] J. Cao, X. Di, J. Li, K. Yu, and L. Zhao, "IoVST: An anomaly detection method for IoV based on spatiotemporal feature fusion," *Future Gener. Comput. Syst.*, vol. 166, p. 107636, April. 2025.
- [5] M. Tsukada, S. Ariei, H. Ochiai and H. Esaki, "Misbehavior Detection Using Collective Perception under Privacy Considerations," *Proceedings of 2022 IEEE 19th Annual Consumer Communications & Networking Conference (CNC)*, pp. 808-814, Jan. 2022.
- [6] A. Lekidis, "Anomaly detection mechanisms for in-vehicle and V2X systems," *Proceedings of the 19th International Conference on Availability, Reliability and Security (ARES '24)*, pp. 100-108, July. 2024.
- [7] K. Nam, "A Study on 5G V2X Capabilities for Vulnerable Road Users and Autonomous Shuttle Vehicles," *Journal of Information Technology Applications & Management*, 32(3), pp. 19-34, Aug. 2025.
- [8] R. W. van der Heijden, T. Lukaseder, and F. Kargl, "VeReMi: A Dataset for Comparable Evaluation of Misbehavior Detection in VANETs," *SecureComm 2018*, pp. 318-333, Dec. 2018.
- [9] T. Alladi, V. Kohli, V. Chamola, and F. R. Yu, "A deep learning based misbehavior classification scheme for intrusion detection in cooperative intelligent transportation systems," *Digital Communications and Networks*, vol. 9, no. 5, pp. 1113-1122, Oct. 2023.

〈저자소개〉



김 준 식 (Jun-sik Kim) 학생회원
2021년 3월~현재 : 세종대학교 정보보호학과 학사과정
〈관심분야〉 이동통신 보안, 네트워크 보안



서 예 린 (Ye-rin Seo) 학생회원
2023년 3월~현재 : 세종대학교 정보보호학과 학사과정
〈관심분야〉 악성코드 분석, 이동통신 보안



김 민 규 (Min-gyu Kim) 학생회원
2023년 3월 : 상명대학교 정보보안공학과 학사
2025년 3월 : 국민대학교 융합보안 이학 석사
2025년 9월~현재 : 세종대학교 정보보호학과 박사과정
〈관심분야〉 사이버 보안, AI 기반 네트워크 보안, 네트워크 이상 탐지, 분산학습, 5G/6G 보안



김 중 현 (Jong-hyun Kim) 정회원
2000년 : University of oklahoma 대학원 컴퓨터과학과 (공학석사)
2005년 : University of oklahoma 대학원 컴퓨터과학과 (공학석사)
2005년~2024년 : ETRI 정보보호연구본부
2024년~현재 : 세종대학교 정보보호학과 교수
〈관심분야〉 네트워크 보안, 클라우드 보안, 악성코드 분석, 5G/6G 보안, etc.