

# Open-RAN 환경 메타학습과 강화 학습 기반 차분 프라이버시 시스템 최적화

차한솔<sup>1\*</sup>, 김종현<sup>2\*</sup>

세종대학교 (학부생)

Optimizing Differential Privacy Systems in Open-RAN Environments with  
Meta-Reinforcement Learning

HanSol Cha<sup>1\*</sup>, Jonghyun Kim<sup>2\*</sup>

Sejong University (Undergraduate student)

## 요약

본 연구는 Open-RAN 환경에서 기존의 차분 프라이버시 기술이 가지는 한계를 해결하고자 하였다. 동적으로 변화하는 네트워크 환경에서 고정된 프라이버시 예산을 사용하는 것은 데이터 효율성을 저해하고 프라이버시 보호하기에 비효율적이다. 이를 극복하기 위해 본 연구는 기존의 구조와 달리 메타학습(MAML)과 강화학습(PPO)을 결합한 구조의 시스템을 제안했다. 이는 다양한 환경의 네트워크 환경을 메타학습을 통해 빠르게 적응하고, 강화학습을 통한 미세조정으로 최적화된 파라미터를 적용한다. 실험 결과로는 제안된 모델은 데이터 처리량을 유지하면서도 학습 수렴 속도를 약 38 % 단축시키고, 위험도 또한 다른 비교 모델보다 더욱 안전한 수치를 보이는 등의 결과를 얻을 수 있었다. 이는 메타학습과 강화학습을 결합한 모델이 차분 프라이버시 기술의 기존 한계점을 극복할 수 있는 가능성을 보여준다.

## I. 서론

### 1.1 연구 배경 및 목적

5G와 6G 네트워크 시대로의 전환이 진행되면서 네트워크의 구조는 Open-RAN이라는 형태로 나타나고 있다. Open-RAN 아키텍처는 높은 효율성을 제공하지만 이러한 변화는 새로운 프라이버시 위협을 야기한다. 특히 복잡한 데이터의 흐름, 처리는 민감한 사용자 정보의 노출 경로를 다변화시킨다. 이를 보호하기 위한 기술로는 차분 프라이버시(DP) 기술이 있는데 기존의 DP 기술의 메커니즘은 프라이버시 예산( $\epsilon$ )을 고정된 값으로 설정하고 적용하는데, 이는 데이터의 분포가 안정적이라는 전제가 필요하다. 하지만 Open-RAN 환경에서는 데이터가 비정상성을 띄고, IoT, MTC 등의 다양한 형태를 하고 있다. 때문에 고정된 예산을 적용하게 되면 프라이버시 보장이 과도해져 효율성이 저해되는 등 동적인 네트워크 환경에서는 효과적으로 대응하지 못할 수 있다. 따라서 본 연구는 기존의 DP 기술의 한계를 극복하는 것을 목표로 한다. 이를 위해 프라이버시 예산을 고정된 상수로 적용하지 않고 메타학습과 강화학습을 활용한 방안을 통해 실제 환경과 상호작용하며 프라이버시 정책을 조정하는 시스템을 구현하고자 한다.

### 1.2 관련 연구

DP 파라미터를 동적으로 조정하려는 시도


는 다양한 분야에서 이루어져 왔으나, 대부분 실시간 네트워크 제어에 적용하기 어려운 한계를 지닌다.

먼저 연합학습 환경에서의 적응형 DP 연구가 진행된 경우 모델의 정확도, 손실 값 등을 기반으로 프라이버시 예산을 동적으로 할당하거나, 딥러닝 모델 가중치의 상대적 중요도에 따라 노이즈를 차등적으로 주입하는 기법을 제안했다[3]. 이러한 접근법들은 모델 성능과 프라이버시 간의 균형을 개선했지만, 사전에 정의된 휴리스틱에 의존하여 변화하는 환경에 대한 일반화 성능이 제한적이며, 실시간 저지연 통신이 요구되는 네트워크 인프라 제어에는 적합하지 않다.

메타학습을 프라이버시 분야에 적용한 연구의 경우, 특정 작업 데이터셋 전체의 통계 정보 유출을 막는 작업 수준의 DP를 보장하거나, 머신러닝 성능과 재식별 위험을 각각 예측하는 두 개의 메타 모델을 사용하여 최적의 프라이버시 파라미터 구성을 자동으로 추천하는 프레임워크를 개발했다[7]. 이 연구들은 메타학습의 잠재력을 보여주었으나, 주로 정적인 데이터 공유 시나리오에서 최적의 설정값을 찾는 데 초점을 맞추고 있어, 실시간으로 변화하는 환경에 대응하여 지속적으로 정책을 조정해야 하는 제어 문제와는 거리가 있다.

## II. 본론

### 2.1. 시스템 아키텍처



시스템은 각각 메타학습, 강화학습, 실시간 Open-RAN 환경으로 구성된다. 데이터셋을 통한 메타학습을 진행하여 강화학습을 위한 초기 파라미터를 설정한다, 이후 실시간 Open-RAN 환경에서의 실시간 데이터(네트워크 처리량, 트래픽 유형, 사용자 및 채널 상태 등)를 통합하여 PPO 알고리즘을 이용한 강화학습을 진행한다. 강화학습은 상태관찰 - 행동 결정 - 보상 획득 - DP 파라미터 업데이트로 진행된다. 상태 관찰 단계는 실시간 데이터들을 입력받는 단계이고, 행동 결정 단계는 현재 정책에 따른 DP 파라미터를 선택하여 출력하는 단계이다. 보상 획득 단계는 행동 결정 단계에서 정한 DP 파라미터를 적용시킨 후의 네트워크 성능과 프라이버시 보호 수준을 종합하여 보상을 받는다. 마지막으로 DP 파라미터 업데이트 단계에서 보상을 바탕으로 DP 파라미터를 조정하게 되고, 이를 바탕으로 정책을 업데이트한다. 이후 실시간 데이터를 바탕으로 강화학습 과정을 반복한다.

### 2.2 실험 및 성능 평가

#### 2.2.1 실험 환경 및 데이터셋

**2.2.1.1 Colosseum ColO-RAN Dataset**  
본 데이터셋은 실제 도시의 기지국 7개와 42명의 이동 사용자로 구성된 고밀도 도심 환경을 모델링하며 eMBB, mMTC 등 다양한 형태의 동적 트래픽이 포함된 데이터이다. 데이터는 사용자가 다운로드 받은 데이터 전송률, 업로드한 전송률, 데이터 전송시 사용된 코딩 방식 등 다양한 지표를 포함하고 있는 데이터이다. 이러한 데이터 형태는 본 연구 목적에 부합하는 형태이다.

#### 2.2.2 비교 모델

| 모델          | 설명                                |
|-------------|-----------------------------------|
| Non-Private | 프라이버시 보호를 전혀 적용하지 않은 상태           |
| Static-Low  | 고정된 낮은 프라이버시 예산( $\epsilon$ )을 사용 |
| Static-High | 고정된 높은 프라이버시 예산( $\epsilon$ )을 사용 |
| RL-only     | 메타학습 없이 강화학습만 단독으로 사용하는 모델        |
| Meta + RL   | 메타학습과 강화학습 모델을 함께 사용하는 모델         |

비교 모델은 총 4가지 유형으로 프라이버시 보호를 적용하지 않은 모델, 프라이버시 예산을 극단적으로 설정한 모델 2개와 강화학습만 적용한 모델, 마지막으로 본 연구에서 제안하는 메타학습과 강화학습을 결합한 모델을 사용하여 평가한다.

#### 2.2.3 평가 지표

| 지표                    | 설명                                                               | 비고                        |
|-----------------------|------------------------------------------------------------------|---------------------------|
| 처리량                   | 특정 시간 동안 사용자에게 전달된 총 데이터의 양을 시간으로 나눈 값                           | 총 전송 데이터(Mb)/측정 시간(s)     |
| $\epsilon$ (프라이버시 예산) | 실질적으로 적용하고 있는 프라이버시 보호 수준, $\epsilon$ 값이 낮을수록 더 강력한 프라이버시를 의미한다. | 사용된 $\epsilon$ 값의 평균      |
| Risk(%)               | MIA(멤버십 추론 공격) 성공률, 50%에 가까울수록 안전                                |                           |
| 학습 수렴속도               | 에이전트의 학습 효율성                                                     | 안정 상태까지 도달하기 위해 필요한 에포크 수 |

#### 2.2.4 성능 비교

| 모델          | 처리량<br>(Mbps) | Risk(%) | $\epsilon$ | 수렴<br>속도 |
|-------------|---------------|---------|------------|----------|
| Non-Private | 369           | 95      | N/A        | N/A      |
| Static-Low  | 194           | 54.5    | 1.0        | N/A      |
| Static-High | 335           | 77.6    | 8.0        | N/A      |
| RL-only     | 334           | 64      | 4.43       | 450      |
| Meta+RL     | 341           | 45.1    | 3.87       | 280      |

처리량에서는 Meta+RL 모델이 다른 모델들과 유사한 성능을 보였다. 이는 메타학습과 강화학습을 적용한 모델이 성능을 희생하지 않고 다른 모델과 같은 수준의 처리량을 유지할 수 있다는 것을 보여준다.

Risk는 MIA 공격 성공률로 50%에 수렴할수록 가장 안전한 상태를 의미한다. 프라이버시를 적용하지 않은 Non-Private 모델은 95%로 보호가 거의 되지 않은 모습을 보이고 있고 RL-only, Meta+RL 모델은 각각 64%, 45.1%로 제안된 모델이 프라이버시 보호 관점에서 가능 탁월한 성능을 보였다.

$\epsilon$ (프라이버시 예산)은 RL-only 모델이 4.43 Meta+RL 모델이 3.87을 기록하였는데 Risk 지표와 함께 비교했을 때 Meta+RL이 더 적은 프라이버시 예산을 사용하여 더 위험성이 낮을 결과를 나타냈다고 볼 수 있다.

마지막으로 학습 효율성을 비교하였을 때 RL-only 모델은 안정적인 성능 도달까지 약 450 에포크가 사용된 반면 Meta+RL 모델은 약 280 에포크가 사용되었다. Meta+RL 모델이 RL-only 모델보다 약 38% 더 빠른 학습 속도이며 그 이유로 메타학습을 통한 초기 파라미터 설정을 들 수 있다.

### III. 결론

본 연구는 동적이고 비정상적인 데이터 특성을 갖는 Open-RAN 환경에서, 기존 DP 기술이 갖 한계점을 극복하기 위해 메타학습과 강화학습을 결합한 자율 최적화 시스템을 제안했다. 실험 결과를 통해 제안 모델의 우수성을 확인할 수 있었다.

네트워크 처리량에서 Meta+RL 모델은 341Mbps의 처리량을 기록하여, Static-Low 모델보다 약 75% 우수하며, Static-High 모델과 대등한 수준의 성능을 유지했다.

프라이버시 보호 측면에서 MIA 공격에 대한 결과로써 제안모델은 45.1%라는 결과를 얻을 수 있었다. 이는 Static-High, RL-only 모델보다 각각 41.9%, 29.5% 낮은 수치로 가장 강력

한 프라이버시 정책을 사용한 Static-Low 모델보다 낮은 수치를 보인 결과이다. 이러한 결과는 메타학습과 강화학습을 결합한 모델이 보안성 측면에서도 충분히 효과를 발휘할 수 있음을 입증한다.

학습 효율성 측면에서 제안 모델은 280 에포크에 최적 성능에 수렴하여, RL-only 모델(450 에포크) 대비 약 38% 더 빠른 학습 속도를 보였습니다. 이는 메타학습이, 강화학습(PPO)에 이진트가 새로운 환경에 더 빠르고 효율적으로 적응할 수 있도록 한다는 것을 보여준다.

결론적으로, 본 연구는 메타학습과 강화학습을 사용해 동적 최적화 모델이 데이터 처리량을 효과적으로 유지하면서 프라이버시 침해 위험을 감소시키고 학습 효율성을 높임으로써, 기존 DP 기술의 한계를 극복할 수 있는 새로운 가능성을 확인할 수 있었다는 점에서 중요한 의의를 가진다. 이는 향후 Open-RAN 환경에서 지능적이고 자율적인 프라이버시 보호 시스템을 구축하기 위한 중요한 기반이 될 것이다.

### Acknowledgement

이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구 결과임 (No. RS-2025-25404706, 6G NTN 글로벌 생태계 신뢰체계 구축 및 국제협력)

### References

- [1]Dan Qiao, Yu-Xiang Wang., Offline Reinforcement Learning with Differential Privacy., 2023
- [2]Xinyu Zhou, Raef Bassily., task-level differential privacy., 2023
- [3]Zhiqiang Wang, Xinyue Yu, Qianli Huang, Yongguang Gong., An Adaptive Differential Privacy Method Based on Federated Learning., 2024
- [4]Mahtab Talaei, Iman Izadi., Adaptive Differential Privacy for Deep Learning in Federated Systems., 2024
- [5]Assem Utaliyeva, Jinmyeong Shin, Yoon-Ho Choi., Task-Specific Adaptive Differential Privacy for Structured Data., 2023
- [6]Tânia Carvalho, Nuno Moniz, Luís Antunes., Automated Privacy-Preserving Techniques via Meta-Learning., 2024
- [7]Ossi Räisä, Stratis Markou, Matthew Ashman, Wessel P. Bruinsma, Marlon Tobaben, Antti Honkela, Richard E. Turner., Noise-Aware Differentially Private Regression via Meta-Learning., 2025